

Kiểm chứng suy giảm và kích hoạt tái huấn luyện dưới data drift với ngân sách nhân hạn chế

Đề cương khóa luận tốt nghiệp – phạm vi thực hiện 5 tháng
Cập nhật ngày 07/09/2026

Tóm tắt. Đề tài nghiên cứu cơ chế quyết định tái huấn luyện khi phân phối dữ liệu đầu vào thay đổi nhưng chỉ một phần dữ liệu production có nhãn. Hệ thống kế thừa Evidently để giám sát data drift, CBPE để ước lượng chất lượng và ATC làm đối chứng; sử dụng một lượng nhân thật trong ngân sách để kiểm chứng trước khi huấn luyện candidate. Đóng góp dự kiến là policy kết hợp kiểm tra định kỳ với yêu cầu nhãn theo bằng chứng, cùng thực nghiệm về đánh đổi giữa sai quyết định, chi phí nhân, chi phí huấn luyện và chất lượng theo thời gian. Phạm vi gồm hai dataset phân loại nhị phân tabular, một model family chính và một recipe retraining cố định. Repo MLOps hiện có được dùng làm nền tảng tích hợp; phần đánh giá hiện trạng chỉ xét các năng lực cần cho đề tài. Kết quả nghiên cứu chưa được thực nghiệm xác nhận.

1 Bài toán, mục tiêu và phạm vi

1.1 Bài toán nghiên cứu

Data drift là thay đổi phân phối đầu vào $P(X)$ giữa reference và production. Cảnh báo drift không tự chứng minh mô hình suy giảm: thay đổi có thể xảy ra ở vùng mô hình vẫn dự đoán tốt. Ngược lại, sai số có thể tăng khi quan hệ $P(Y | X)$ thay đổi mà detector đầu vào không phát hiện. Do đó, giám sát drift và kiểm chứng chất lượng là hai nguồn bằng chứng bổ sung.

Ở thời điểm quyết định t , hệ thống quan sát batch production, prediction và xác suất của mô hình đang phục vụ; chỉ được đọc nhãn đã nhận hoặc được yêu cầu trong ngân sách. Cần lựa chọn KEEP, REQUEST_LABELS, HOLD hoặc RETRAIN. Khi không đủ bằng chứng, kết quả là chưa xác định; không gán mặc định mô hình khỏe. Ước lượng không nhân phụ thuộc giả định về shift và calibration, không bảo đảm nhận diện mọi suy giảm [1, 2].

1.2 Câu hỏi nghiên cứu và đóng góp dự kiến

- RQ1:** Kiểm chứng bằng một mẫu nhân thật giúp giảm bao nhiêu quyết định retraining sai hoặc bỏ sót so với chỉ dùng cảnh báo drift hay ước lượng không nhãn?
- RQ2:** Với cùng giới hạn ngân sách nhân, policy kết hợp kiểm tra định kỳ và yêu cầu nhãn theo bằng chứng có duy trì chất lượng tốt hơn policy lấy nhãn theo lịch cố định, khi dùng cùng recipe retraining không?

Đóng góp gồm: (i) cơ chế phân bổ nhân kiểm chứng trước quyết định retraining; (ii) protocol và benchmark tái lập đánh giá tác động lên cả vòng huấn luyện; (iii) tích hợp một luồng thử nghiệm vào repo. Không đề xuất detector, estimator hay lý thuyết thông kê mới. Thành công được đánh giá bằng kết quả có đối chứng và phân tích giới hạn, kể cả khi policy đề xuất không vượt baseline.

1.3 Ranh giới thực hiện trong 5 tháng

- Cốt lõi:** Hai dataset nhị phân tabular, một model family có xác suất lớp; CBPE chính, ATC đối chứng; nhân kiểm chứng lấy ngẫu nhiên; một recipe full-retraining; đánh giá offline và demo tích hợp cục bộ.
- Giả định nhân:** Dataset thực nghiệm có nhãn đầy đủ ở phía evaluator. Hệ thống chỉ nhận phần được tiết lộ theo ngân sách sau mỗi batch. Nhãn đúng, chi phí một đơn vị/mẫu; phần còn lại chưa được phép đọc. Yêu cầu nhãn được mô phỏng, không phải nghiên cứu hành vi người gán nhãn.
- Ngoài phạm vi:** Taxonomy nguyên nhân, causal diagnosis, học policy bằng reinforcement learning, tối ưu sampler, incremental training, pseudo-labeling, nhân thử/sửa nhân phức tạp, human study và canary production.

Trường hợp không lấy được bất kỳ nhãn production nào chỉ dùng kiểm tra giới hạn giám sát. Không cam kết supervised retraining trên dữ liệu không nhãn. Tên dataset, cấu hình model, mức ngân sách và ngưỡng được chọn qua pilot ở tháng 1 rồi đóng băng trước test.

2 Cơ sở kế thừa và định vị đóng góp

Bảng 1: Các công trình trực tiếp phục vụ đề tài.

Công trình	Phần kế thừa	Giới hạn và cách sử dụng
ATC, ICLR 2022 [1]	Học ngưỡng confidence trên reference có nhãn để ước lượng accuracy trên target	Baseline nhẹ; hiệu quả phụ thuộc dạng shift, không chứng minh được suy giảm trong mọi môi trường
CBPE, Machine Learning 2026 [2]	Ước lượng confusion matrix và metric từ xác suất đã calibration	Estimator chính; calibration tốt trên reference không bảo đảm tốt trên production
MLDemon, AISTATS 2022 [3]	Kết hợp tín hiệu không nhãn và yêu cầu nhãn theo ngân sách để giám sát	Tiền lệ gần nhất cho policy; đối chiếu giả định và đánh giá thêm tác động lên retraining
Active Testing, ICML 2021 [4]	Phân biệt chọn mẫu đánh giá và chọn mẫu huấn luyện; xử lý thiên lệch lấy mẫu	Bản đầu dùng mẫu ngẫu nhiên để giới hạn độ phức tạp; không tuyên bố thuật toán active testing mới
Modyn, SIGMOD 2025 [5]	Tách trigger khỏi data-selection policy, đánh giá pipeline theo thời gian	Kế thừa cách tổ chức benchmark; giữ recipe cố định, không xây lại toàn bộ nền tảng

Các thành phần trên đã có trong nghiên cứu trước. Khoảng cần kiểm chứng của khóa luận là **giá trị của bước lấy thêm nhãn trước một quyết định retraining**: mức giảm sai quyết định có bù được chi phí nhãn và độ chậm phục hồi hay không. Đóng góp được giới hạn vào policy cụ thể, tích hợp và bằng chứng thực nghiệm trên phạm vi đã chốt; không khẳng định là hệ thống đầu tiên kết hợp monitoring, nhãn và retraining.

Tháng 1 lập bảng đối chiếu các nghiên cứu gần nhất theo tín hiệu đầu vào, cơ chế yêu cầu nhãn, ngân sách, action set, dữ liệu huấn luyện, cách đánh giá và mã nguồn. Nếu policy trùng công trình có trước, xác định rõ đây là tái hiện/mở rộng thực nghiệm và điều chỉnh tuyên bố đóng góp. PAPE [6] là đối chứng mở rộng phù hợp cho covariate shift nếu thời gian cho phép; không là điều kiện hoàn thành.

3 Mức đáp ứng của hệ thống hiện tại

3.1 Cách đánh giá và phạm vi bằng chứng

Đánh giá bằng đọc mã nguồn tại commit cde7dcb, ngày 07/09/2026; không suy ra trạng thái vận hành của cluster. Đơn vị đánh giá là **năng lực cần cho đề tài**, không dùng bộ thành phần hay thang trưởng thành của một khung kiến trúc MLOps.

- **Đầy đủ:** Có implementation đáp ứng năng lực được mô tả ở hàng tương ứng; có thể kế thừa sau kiểm tra tích hợp.
- **Một phần:** Có phần nền nhưng còn thiếu dữ liệu, contract hoặc xử lý cần cho thí nghiệm.
- **Thiếu:** Chưa tìm thấy implementation đáp ứng năng lực trong các luồng đã kiểm tra.

Mức “Đầy đủ” chỉ áp dụng cho yêu cầu hẹp trong bảng, không có nghĩa toàn bộ pipeline đã sẵn sàng hay được kiểm chứng production.

Bảng 2: Hiện trạng repo đối với đề tài đã chốt.

Năng lực cần có	Mức độ	Bằng chứng hiện tại và phần cần bổ sung
Lưu prediction và identity	Một phần	E1–E2 có prediction ID, thời gian, tenant/project/version và features. Cần kiểm soát tính đầy đủ của batch; producer gửi sự kiện thành công theo cơ chế best-effort.
Xác suất lớp cho CBPE/ATC	Một phần	E3 chỉ trả max confidence thang 0–100. Cần xác suất lớp dương 0–1, class mapping, decision threshold và calibration version.

Năng lực cần có	Mức độ	Bằng chứng hiện tại và phần cần bổ sung
So sánh phân phối, xuất báo cáo	Đầy đủ	E4 chạy Evidently với reference/production, sinh báo cáo và summary. Kế thừa detector, pin phiên bản và hiệu chỉnh ngưỡng trên development stream.
Kiểm tra dữ liệu đầu vào	Một phần	E4 kiểm tra thiếu cột, null cao; gộp cột thiếu vào drift tổng hợp. Cần tách lỗi contract khỏi statistical drift và chặn batch không hợp lệ.
Cửa sổ dữ liệu tái lập	Một phần	E4 lấy các bản ghi mới nhất theo version. Cần chốt khoảng thời gian, danh sách prediction ID và snapshot reference trước chạy.
Kích hoạt tác vụ giám sát	Một phần	E5 có khóa, watermark theo số lượng bản ghi và idempotency cho DriftRun. Chưa có audit nhãn hay trigger retraining theo chất lượng.
Feedback và ngân sách nhãn	Thiếu	E2/E5 chưa có nhận nhãn gắn prediction và quản lý mục đích, quota, nhãn đã tiết lộ. Cần LabelRequest, Feedback và budget ledger.
Ước lượng, kiểm chứng suy giảm	Thiếu	Chưa có CBPE/ATC, baseline chất lượng theo version, khoảng bất định và kiểm chứng trên mẫu nhãn ngẫu nhiên.
Policy quyết định retraining	Thiếu	Chưa có vòng KEEP, REQUEST_LABELS, HOLD, RETRAIN với bằng chứng quyết định và giới hạn yêu cầu nhãn.
Chạy job với snapshot đầu vào	Đầy đủ	E6 tạo TrainingJob, snapshot source/data và submit qua execution backend. Tái sử dụng để chạy recipe cố định.
Tạo training set từ production	Một phần	E6 nhận file training data nhưng mặc định lấy workspace asset mới nhất. Cần nối nhãn và xuất snapshot từ pool production hợp lệ.
Đăng ký candidate sau build	Đầy đủ	E7 tạo ModelVersion và lưu artifact/metrics khi build thành công. Kế thừa lưu vết candidate.
Đánh giá candidate độc lập	Thiếu	Metrics được ingest chưa thay thế evaluator tin cậy. Cần holdout riêng, so sánh champion và quyết định pass/fail/hold.
Benchmark ngân sách nhãn	Thiếu	Chưa có replay che nhãn, policy đối chứng và thống kê chi phí/chất lượng của đề tài.

3.2 Các điểm mã nguồn làm căn cứ

Các đường dẫn tính từ gốc repo, chỉ dẫn tới chức năng đã kiểm tra:

- **E1:** services/model-server/src/index.py, gửi event và endpoint predict.
- **E2:** services/consumer/src/database.py, production logs và automatic-drift outbox.
- **E3:** services/machine-learning-serving/src/index.py, xử lý predict_proba.
- **E4:** services/evidently/src/main.py, load_production_data và run_drift_analysis.
- **E5:** services/control-plane/src/apps/drift/services/automatic.py, tạo DriftRun.
- **E6:** services/control-plane/src/apps/training/services/jobs.py, tạo/submit job và snapshot.
- **E7:** services/control-plane/src/apps/registry/services/versions.py, đăng ký version.

Nền tảng có các khối suy luận, drift report, chạy training và lưu candidate. Khối cần xây nằm ở **feedback, ngân sách, kiểm chứng và quyết định**; không cần phát triển thêm hạ tầng AWS/Kubernetes để bắt đầu thực nghiệm.

4 Phương pháp đề xuất

4.1 Tổ chức dữ liệu và ngân sách nhãn

Chia dữ liệu ban đầu thành các tập tách biệt: D_{train} để huấn luyện, D_{cal} để calibration/fit ATC và D_{ref} để lấy mốc drift, chất lượng. Mỗi version có estimator và mốc chất lượng riêng; sau khi thay champion phải fit lại estimator từ calibration data hợp lệ và ghi nhận mốc mới.

Batch production W_t được lưu prediction *trước* khi tiết lộ nhãn. Trước khi đọc nhãn, dùng seed để phân vai các mẫu thành pool kiểm chứng, huấn luyện và đánh giá candidate. Các pool là mẫu ngẫu nhiên của cùng batch và không trùng ID. Chỉ pool kiểm chứng được dùng kết luận chất lượng champion; pool huấn luyện dùng tạo dataset; pool đánh giá dành riêng cho candidate. Nhãn không được tái sử dụng sang pool khác trong thí nghiệm chính.

Đặt B là giới hạn số nhãn production được tiết lộ trên một episode. Ghi sổ ba khoản:

$$B_{\text{used}} = B_{\text{verify}} + B_{\text{train}} + B_{\text{gate}} \leq B.$$

Tất cả nhãn trả về, kể cả khi không retrain hoặc candidate bị loại, đều được tính; retry cùng ID không tính lại. Quota theo mục đích và lịch cấp nhãn huấn luyện được cố định trên development. Trong so sánh policy kiểm chứng, các phương pháp có cùng lịch và pool nhãn huấn luyện, tránh lợi ích chỉ do được cấp thêm training labels. Quota kiểm chứng gồm phần dành cho audit định kỳ và phần cho yêu cầu bổ sung; không tiêu hết phần audit vào các cảnh báo sớm.

4.2 Ước lượng và điều kiện xác nhận suy giảm

Evidently theo dõi X trên toàn batch hợp lệ. CBPE fit bằng reference/calibration có nhãn và ước lượng chất lượng từ xác suất lớp dương trên production [2]. ATC được fit độc lập trên cùng split làm baseline [1]. Cấu hình đầu tiên dùng tỷ lệ lỗi $e = 1 - \text{accuracy}$ làm metric quyết định chung vì cả hai estimator đều hỗ trợ; F1, recall và Brier là metric báo cáo bổ sung. Nếu lớp hiếm quá ít, không đưa kết luận riêng về recall của lớp đó.

Đặt e_{ref} là tỷ lệ lỗi champion trên D_{ref} , $\Delta_t = e_t - e_{\text{ref}}$ là mức suy giảm. Estimator cung cấp $\hat{\Delta}_t$ để gợi ý lấy nhãn, không phải ground truth. Với khoảng kiểm chứng $I_t = [L_t, U_t]$ từ mẫu nhãn thật:

- $L_t > \delta_{\text{harm}}$: xác nhận suy giảm vượt biên thực tiễn.
- $U_t \leq \delta_{\text{keep}}$: có bằng chứng giữ mô hình trong biên chấp nhận.
- Các trường hợp khác: chưa xác định; với $0 \leq \delta_{\text{keep}} \leq \delta_{\text{harm}}$.

Khoảng kiểm chứng phải tính bất định của cả mẫu production và mốc reference. Bản đầu cho phép tối đa hai lần đọc kết quả trong một cửa sổ, với cỡ mẫu dự kiến xác định trước. Lấy mẫu bằng tiền tố của một hoán vị ngẫu nhiên độc lập với nhãn; dùng cận cho sai số nhị phân và phân bổ mức lỗi thống kê giữa các lần đọc và mốc reference. Không dùng CI cố định rồi xem lập vô hạn. Mức bảo đảm phát biểu theo cửa sổ; false-alarm toàn stream được đo riêng. Calibration và repeated testing là giới hạn cần báo cáo.

4.3 Policy kiểm chứng trong giới hạn ngân sách

Policy có tham số cố định: lịch audit k , cỡ mẫu ban đầu m_1 , cỡ mẫu bổ sung m_2 , ngưỡng drift, ngưỡng estimator, mức bất đồng và cooldown. Thực hiện theo thứ tự:

1. Kiểm tra contract, tính đầy đủ của batch và reference. Nếu lỗi, trả HOLD và ghi lý do; chưa dùng batch để retrain.
2. Tính drift và ước lượng chất lượng. Bắt đầu kiểm chứng khi đến kỳ audit, có drift hoặc estimator nghi suy giảm. Audit định kỳ vẫn chạy khi cả hai tín hiệu im lặng.
3. Nếu còn quota, yêu cầu mẫu ngẫu nhiên m_1 ở pool kiểm chứng. Khi I_t đã phân loại được, quyết định theo bảng 3.
4. Nếu chưa xác định hoặc estimator bất đồng rõ với nhãn thật, dùng tối đa một lượt bổ sung m_2 từ cùng hoán vị, rồi cập nhật khoảng kiểm chứng theo quy tắc hai lượt. Estimator không có quyền phủ quyết kết quả nhãn thật.
5. Khi hết quota, thiếu mẫu hoặc vẫn chưa xác định, trả HOLD, ghi hẹn audit tiếp theo. Không diễn giải HOLD thành mô hình khỏe.

Bảng 3: Quyết định sau kiểm chứng.

Hành động	Điều kiện và kết quả
KEEP	Khoảng kiểm chứng nằm trong biên chấp nhận; lưu bằng chứng, tiếp tục giám sát.
REQUEST_LABELS	Cần kiểm chứng và còn lượt/quota; chọn ID trước khi đọc nhãn, lưu chi phí.
HOLD	Chưa đủ bằng chứng, hết ngân sách, dữ liệu lỗi hoặc chưa đủ dữ liệu huấn luyện; có lý do và thời điểm xét lại.
RETRAIN	Nhãn thật xác nhận suy giảm, pool training đủ mẫu/lớp, còn quota đánh giá và không có job cùng champion đang chạy. Tạo candidate theo recipe cố định.

Phần cần kiểm chứng thực nghiệm là lợi ích của phân bổ audit theo bằng chứng so với lịch cố định. Không tự động học hay thay đổi tham số policy trên test. Không trộn F1 đo từ mẫu có nhãn với F1 ước lượng trên phần không nhãn bằng trung bình tùy ý.

4.4 Recipe retraining và đánh giá candidate

Recipe giữ nguyên model family, preprocessing, hyperparameters và phương thức huấn luyện từ đầu. Dataset gồm nhãn production thuộc pool training trong cửa sổ gần nhất, trộn tỷ lệ cố định từ D_{train} . Dùng lấy mẫu ngẫu nhiên/phân tầng với seed; cố định cửa sổ, tỷ lệ trộn và giới hạn số mẫu qua pilot. Dành calibration split không trùng training cho candidate. Khi thiếu dữ liệu/lớp, HOLD thay vì dùng nhãn giả.

Luồng thực thi là **TrainingJob** → **TrainingOutput** → **Build/Register candidate** → **EvaluationGate**. Gate dùng mẫu production riêng có nhãn được tính vào B_{gate} ; so sánh lỗi candidate và champion theo cặp trên cùng mẫu. Candidate chỉ pass khi lợi ích vượt biên đã định và không suy giảm quá biên trên historical holdout. Một gate dùng cỡ mẫu định trước; không mở rộng mẫu tùy kết quả trong MVP. Thiếu bằng chứng trả HOLD; fail không đổi champion. Mọi candidate đều được tính chi phí.

Trong replay, candidate pass được kích hoạt cho batch sau khi job/gate hoàn tất; champion cũ phục vụ trong thời gian chờ. Demo dùng chuyển version có kiểm soát. Không đồng nhất đăng ký version với cải thiện chất lượng hoặc tự động triển khai production.

5 Thiết kế tích hợp vào repo

5.1 Phân công trách nhiệm

Consumer tiếp tục sở hữu ingestion và bằng prediction; Evidently giữ chức năng tạo drift report. Control Plane điều phối cửa sổ, yêu cầu nhãn, ngân sách và quyết định. Calculation của CBPE/ATC, khoảng kiểm chứng và policy được tách thành thư viện thuần, dùng chung trong replay và worker để tránh hai implementation khác nhau.

Bảng 4: Các đối tượng tối thiểu cần bổ sung.

Đối tượng	Thông tin và ràng buộc chính
PredictionRecord mở rộng	Prediction ID, tenant/project/version, event time, features, predicted class, xác suất lớp dương, class mapping và calibration version. Giữ tương thích trường confidence cũ.
LabelRequest / Feedback	ID mẫu, mục đích verify/train/gate, seed, thời điểm yêu cầu/nhận nhãn, trạng thái và chi phí. Chỉ nổi feedback khi identity khớp.
BudgetLedger	Quota và khoản đã giữ/chốt theo episode, mục đích và request; retry không chỉ hai lần, không vượt ngân sách khi có request đồng thời.
EvidenceWindow	Danh sách ID và reference snapshot, champion, kết quả drift/estimator/audit, số nhãn và thời điểm chốt. Nhãn chưa được cấp không xuất hiện trong view của policy.
MaintenanceDecision	Action, reason, phiên bản policy, evidence snapshot, các chi phí liên quan và TrainingJob nếu có; lưu cả KEEP/HOLD.
DatasetSnapshot / EvaluationGate	Manifest train/calibration/gate, recipe và hash dữ liệu; kết quả so sánh theo cặp, trạng thái pass/fail/hold và candidate version.

5.2 Luồng triển khai tối thiểu và kiểm tra

Luồng tích hợp: **Prediction** → **EvidenceWindow** → **LabelRequest/Feedback** → **MaintenanceDecision** → **TrainingJob** → **Build/Register** → **EvaluationGate**. Tác vụ qua service, transaction commit, Celery và execution backend hiện có; không để Consumer gọi training trực tiếp.

Mỗi request có idempotency key; giữ ngân sách trong transaction trước khi phát tác vụ. Tại một thời điểm chỉ có một maintenance job cho cùng champion; callback lặp hoặc đến muộn không khởi động lại quyết định đã kết thúc. Feedback và truy vấn evidence luôn giới hạn theo tenant/project/version. Không thay đổi quyền truy cập chung hay topology hạ tầng trong phạm vi đề tài.

Kiểm tra bắt buộc gồm: dự đoán trước khi có nhãn; không đọc nhãn ẩn; không trùng mẫu giữa train/gate/audit; retry không nhân đôi nhãn/job; HOLD khi thiếu lớp hoặc ngân sách; candidate fail không đổi champion. Demo tối thiểu thể hiện một lần KEEP, một lần yêu cầu nhãn bổ sung và một candidate đi qua training/gate. Nếu dùng giao diện, chỉ cần trang trạng thái và bằng chứng; dashboard nâng cao không phải đầu ra nghiên cứu.

6 Thiết kế thực nghiệm và tiêu chí đánh giá

6.1 Dữ liệu, kịch bản và chống rò rỉ

Chọn hai dataset tabular nhị phân có nguồn/giấy phép rõ ràng, đủ số mẫu và cả hai lớp ở các cửa sổ; ưu tiên ít nhất một dataset có thời gian hoặc nhóm miền tự nhiên. Bộ sinh dữ liệu có nhãn phục vụ kiểm soát cơ chế drift. Dùng một model family có xác suất lớp; đề xuất bắt đầu từ logistic regression. Một model phi tuyến chỉ là kiểm tra độ nhạy nếu còn thời gian.

Chia riêng initial training/calibration/reference, development episodes để chọn cấu hình và test episodes để báo cáo. Nếu có thời gian/entity, chia theo chúng trước khi tạo batch; không đưa cùng thực thể vào hai phía trái với mục tiêu đánh giá. Giữ bộ seed test riêng. Future labels và cơ chế tạo drift chỉ thuộc evaluator, không thuộc estimator/policy.

Bảng 5: Kịch bản và vai trò trong thực nghiệm.

Kịch bản	Mục đích
Ổn định	Đo false-alarm, chi phí giám sát và việc tiêu ngân sách khi không có suy giảm.
Covariate shift với nhiều mức tác động	Đo drift có/không đi kèm suy giảm và khả năng phục hồi. Tạo shift bằng lấy mẫu theo X trong khi giữ cơ chế sinh nhãn; không tùy ý sửa X rồi giữ nhãn cũ.
Phân phối quay lại	Đo tác động giữ dữ liệu lịch sử trong recipe cố định và chất lượng xuyên nhiều đợt cập nhật.
Concept drift, calibration không còn phù hợp	Kiểm tra giới hạn estimator; audit định kỳ có phát hiện suy giảm bị tín hiệu không nhãn bỏ sót không.
Nhãn quan sát có thiên lệch	Stress test khi mẫu nhãn không còn đại diện; báo cáo sai số và không suy rộng bảo đảm của mẫu ngẫu nhiên.
Không lấy thêm được nhãn	Đo giới hạn ước lượng/HOLD; không xem là bài toán supervised retraining đã được giải quyết.

Ba hàng đầu là kịch bản chính; ba hàng sau kiểm tra giới hạn với số cấu hình gọn. Độ có hại được đo trên champion của từng policy, không gán cứng từ tên drift. Trên dữ liệu thực, không tuyên bố suy giảm có nguyên nhân nhân quả đã biết. Không lọc test episodes theo việc phương pháp đề xuất thắng.

6.2 Các phương pháp đối chứng

Bảng 6: Baseline dùng cùng recipe và gate, trừ đối chứng không cập nhật.

Mã	Phương pháp	Vai trò
B0	Giữ nguyên mô hình	Đường chất lượng và chi phí khi không retrain.
B1	Drift-only trigger	Cảnh báo Evidently đủ để thử retrain, không audit trước trigger; gate vẫn dùng nhãn riêng.
B2	Estimator-only trigger	CBPE hoặc ATC nghi suy giảm thì thử retrain; đo hậu quả của không kiểm chứng trước trigger.
B3	Audit theo lịch cố định	Lấy nhãn ngẫu nhiên theo lịch, quyết định từ chất lượng đo được; không dùng drift/estimator để phân bổ nhãn.
B4	Policy đề xuất	Audit định kỳ kết hợp kiểm chứng theo tín hiệu và một lượt bổ sung; quyết định theo Mục 4.

Mã	Phương pháp	Vai trò
B5	Đối chứng đầy đủ nhân	Có mọi nhân ở pool kiểm chứng; giữ cùng training pool và recipe để đo khoảng cách thông tin. Báo cáo chi phí nhân riêng, không coi là baseline cùng ngân sách.

B1–B4 cùng giới hạn ngân sách tổng, quota theo mục đích, giới hạn compute, lịch nhân training và điều kiện gate. Ngân sách bằng nhau không có nghĩa số nhân thực dùng bằng nhau: báo cáo cả quota và chi tiêu, kèm đường chất lượng theo chi phí thực. Không cấp nhân gate miễn phí cho B1/B2. B3 là đối chứng performance-only quan trọng vì nhân có thể đủ hữu ích ngay cả khi không dùng drift.

Thực nghiệm estimator CBPE/ATC được đánh giá riêng trên cùng prediction stream. Để kiểm tra quyết định B3/B4, trước hết dùng cùng champion cố định; sau đó chạy replay có retraining để đo hiệu quả toàn vòng. Ablation chính của B4 lần lượt bỏ tín hiệu drift, bỏ audit định kỳ và bỏ lượt nhân bổ sung; giữ các yếu tố khác tương đương. Policy kế thừa MLDemon hoặc estimator PAPE có thể thêm sau khi tái hiện được, nhưng không gọi bản đơn giản hóa là thuật toán gốc và không tuyên bố vượt state of the art nếu chưa so sánh.

6.3 Chỉ số và cách đo đánh đổi

Bảng 7: Định nghĩa chỉ số dùng trong báo cáo.

Nhóm	Cách đo
Ước lượng chất lượng	MAE giữa tỷ lệ lỗi ước lượng và tỷ lệ lỗi đầy đủ của batch; độ phủ/độ rộng khoảng nếu phương pháp cung cấp khoảng hợp lệ.
Sai quyết định	Tỷ lệ trigger khi Δ_t đầy đủ không vượt biên có hại; tỷ lệ episode suy giảm không được kích hoạt trong deadline đã định. Tách HOLD, thiếu training data và hết ngân sách khỏi KEEP có bằng chứng.
Chất lượng hệ thống	Tỷ lệ lỗi theo batch và tổng lỗi theo số prediction; F1/recall bổ sung; thời gian đến lúc chất lượng trở lại biên chấp nhận. Episode chưa phục hồi khi hết test được ghi chưa phục hồi.
Chi phí nhân	Số ID được tiết lộ theo verify/train/gate, tỷ lệ trên production và số request. Nhân ẩn dùng riêng chấm benchmark không thuộc thông tin online.
Chi phí tính toán	Thời gian/CPU-hours cho estimator, chọn mẫu, training, build và gate; số mẫu học, số job và số candidate bị loại. Tách phép đo thật khỏi độ trễ mô phỏng.
Lợi ích retraining	Chênh lệch chất lượng candidate–champion trên cùng gate và trên batch tương lai; chất lượng historical holdout. Phân biệt trigger hợp lý với candidate thực sự cải thiện.

Đề đo đánh đổi KEEP/RETRAIN, trên một tập thời điểm được chọn trước khi xem nhân test, clone cùng checkpoint thành hai nhánh: giữ mô hình và chạy recipe với cùng nhân training được phép. So sánh trên cùng các batch tương lai; thông tin này chỉ để phân tích hồi cứu, không quay lại policy. Chi phí các nhánh phân tích được báo cáo riêng, không trộn với chi phí vận hành của phương pháp.

6.4 Protocol thống kê và điều kiện kết luận

Thử một số mức ngân sách, chẳng hạn 5%, 10%, 20% số mẫu production và đối chứng đầy đủ nhân; đây là lưới pilot, chỉ giữ cấu hình đủ mẫu kiểm chứng/huấn luyện/gate. Cố định ngưỡng, phân bổ quota, batch size, số lượt audit, recipe, seed và thời hạn phục hồi trước test. Ưu tiên 10 seed độc lập nếu pilot xác nhận đủ tài nguyên; chốt số lần lặp trước chạy chính thức.

So sánh theo cặp trên cùng dataset/episode/seed, bootstrap ở cấp episode hoặc block thời gian, không coi các batch phụ thuộc là mẫu độc lập. Báo cáo khoảng tin cậy và mức khác biệt thực tiễn; hiệu chỉnh khi kiểm định nhiều so sánh chính. Kết luận tiết kiệm phải đi kèm chất lượng nằm trong biên non-inferiority đã chốt; $p > 0.05$ không chứng minh tương đương. Trình bày riêng giới hạn do lớp hiếm, selection bias, calibration sai và repeated testing. Không hứa tỷ lệ tiết kiệm hoặc mức accuracy cải thiện trước khi thực nghiệm.

7 Kế hoạch 5 tháng, đầu ra và giới hạn

Bảng 8: Các mốc triển khai và tiêu chí nghiệm thu.

Tháng	Công việc trọng tâm	Đầu ra kiểm chứng được
1	Đối chiếu paper gần nhất, chọn dataset/model, tái hiện CBPE/ATC và pilot ngân sách	Protocol version 1: split, metric, cỡ mẫu, ngưỡng, quota ba mục đích, recipe và seed; xác nhận chạy được trên tài nguyên hiện có
2	Replay che nhãn, audit, ledger, B0–B4 và khoảng kiểm chứng	Unit tests không rò rỉ nhãn/không vượt quota; replay tái lập; báo cáo pilot chưa dùng final test
3	Mở rộng xác suất, feedback/window, nối policy với TrainingJob và gate	Demo cục bộ KEEP, yêu cầu bổ sung nhãn, candidate pass/fail/hold; kiểm tra retry và snapshot
4	Chạy benchmark chính, B5, ablation và các stress test đã chốt	Kết quả RQ1/RQ2, khoảng tin cậy, bảng chi phí và phân tích thất bại
5	Hoàn thiện phân tích, báo cáo và demo; dự phòng sửa lỗi	Mã nguồn, manifest dữ liệu/cấu hình, script chạy lại, kết quả và giới hạn có thể kiểm tra

Đầu ra bắt buộc: Một policy kiểm chứng trong ngân sách; luồng tích hợp thử nghiệm; benchmark hai dataset với baseline và ablation; báo cáo trả lời hai RQ. PAPE, model family thứ hai và giao diện nâng cao chỉ làm nếu các đầu ra này đã hoàn thành.

Rủi ro trọng yếu và xử lý:

- **Nhãn quá ít:** Pilot kiểm tra cỡ mẫu và độ rộng khoảng trước khi chốt ngân sách. Chấp nhận HOLD và báo cáo giới hạn, không thu hẹp khoảng bằng cách bỏ bất định.
- **Estimator mất calibration:** Audit định kỳ không phụ thuộc cảnh báo; fit estimator theo version và kiểm tra concept drift như trường hợp giới hạn.
- **Tiết kiệm giả do bỏ sót chi phí hoặc leakage:** Ledger tính đủ ba mục đích; tách train/calibration/gate, khóa nhãn ẩn và ghi chi phí candidate bị loại.
- **Phạm vi vượt thời gian:** Giữ một recipe, một model family, mô phỏng gán nhãn và triển khai cục bộ; cắt đối chứng mở rộng trước baseline/ablation cốt lõi.
- **Policy không tốt hơn baseline:** Báo cáo điều kiện thất bại và đánh đổi quan sát được. Không sửa ngưỡng theo final test hay mở rộng tuyên bố từ hai dataset.

Đề tài đánh giá khả năng ra quyết định dưới bằng chứng nhãn hạn chế. Hoàn thành khóa luận không đồng nghĩa hệ thống đã tự động chẩn đoán mọi nguyên nhân suy giảm hoặc đủ điều kiện vận hành tự trị trong production.

Tài liệu tham khảo

- [1] S. Garg, S. Balakrishnan, Z. C. Lipton, B. Neyshabur, and H. Sedghi, “Leveraging unlabeled data to predict out-of-distribution performance,” *ICLR*, 2022. <https://arxiv.org/abs/2201.04234>.
- [2] J. Kivimäki, J. Białek, W. Kuberski, and J. K. Nurminen, “Performance estimation in binary classification using calibrated confidence,” *Machine Learning*, vol. 115, Art. 67, 2026. <https://doi.org/10.1007/s10994-025-06970-3>.
- [3] T. Ginart, M. J. Zhang, and J. Zou, “MLDemon: Deployment monitoring for machine learning systems,” *AISTATS*, PMLR, vol. 151, pp. 3962–3997, 2022. <https://proceedings.mlr.press/v151/ginart22a.html>.
- [4] J. Kossen, S. Farquhar, Y. Gal, and T. Rainforth, “Active testing: Sample-efficient model evaluation,” *ICML*, PMLR, vol. 139, pp. 5753–5763, 2021. <https://proceedings.mlr.press/v139/kossen21a.html>.
- [5] M. Böther, T. Robroek, V. Gsteiger, R. Holzinger, X. Ma, P. Tözün, and A. Klimovic, “Modyn: Data-centric machine learning pipeline orchestration,” *Proceedings of the ACM on Management of Data*, vol. 3, no. 1, Art. 55, 2025. <https://doi.org/10.1145/3709705>.
- [6] J. Białek, J. Kivimäki, W. Kuberski, and N. Perrakis, “Estimating model performance under covariate shift without labels,” *NeurIPS*, vol. 38, 2025. <https://arxiv.org/abs/2401.08348>.