

Đánh giá kiến trúc MLOps và lộ trình Degradation-Aware CT

Hiện trạng, khoảng trống và lộ trình Degradation-Aware Continuous Training

August 29, 2026

Abstract

Báo cáo này tiến hành đánh giá toàn diện repository MLOps PaaS dựa trên khung kiến trúc tham chiếu chuẩn mực của Amou Najafabadi *et al.* [1]—một nghiên cứu tổng hợp (systematic mapping study) từ 93 công trình khoa học, bao quát 39 thành phần kiến trúc, 56 bước quy trình và 15 vai trò stakeholder. Kết quả phân tích mã nguồn thực tế cho thấy hệ thống đã thiết lập nền tảng vững chắc cho một nền tảng vận hành mô hình (MLOps PaaS): control plane phân tách đa tenant, registry quản lý phiên bản bất biến, hạ tầng huấn luyện đa backend (Docker/Argo/Kubeflow), dịch vụ đóng gói tự động (model-packager), serving gateway và luồng thu thập production log phục vụ giám sát data drift.

Tuy nhiên, đối chiếu theo phân loại của nghiên cứu tham chiếu, hệ thống hiện dừng lại ở biến thể **V1 (Inference Service + Manual Retraining)**, chưa hình thành vòng lặp **Continuous Training (CT - biến thể V3)** khép kín. Các khoảng trống kiến trúc trọng yếu bao gồm: thiếu cơ sở dữ liệu phản hồi nhận thực tế (Feedback Database), chưa có cơ chế đánh giá hiệu năng suy giảm (performance degradation), thiếu công cụ so sánh tự động candidate–champion và chưa hỗ trợ điều phối lưu lượng shadow/canary. Trên cơ sở đó, báo cáo đề xuất hướng nghiên cứu và luận đề **“Degradation-Aware Adaptive Model Maintenance”** (Bảo trì mô hình thích ứng nhận thức suy giảm), phân tách tường minh ba lớp: phát hiện (detection), chẩn đoán nguyên nhân (diagnosis) và ra quyết định hành động (action selection). Trong kiến trúc này, tái huấn luyện (retraining) là một hành động có điều kiện kiểm chứng nghiêm ngặt thay vì phản xạ mặc định sau mỗi cảnh báo drift.

1 Phạm vi và phương pháp đánh giá

1.1 Khung kiến trúc tham chiếu

Nghiên cứu tham chiếu của Amou Najafabadi *et al.* [1] mô tả hệ thống MLOps thông qua hai chiều cạnh cấu trúc cốt lõi:

- **Cấu trúc tĩnh (Structure):** Gồm 39 thành phần chức năng được phân bổ trong 6 nhóm: (1) Data Curation, (2) Storage & Versioning, (3) ML Training, (4) CI/CD, (5) Inference, và (6) Infrastructure & Supporting Services.
- **Quy trình động (Process):** Gồm 56 bước quy trình bao quát trọn vẹn vòng đời từ thu thập dữ liệu, huấn luyện, kiểm thử, triển khai đến giám sát và bảo trì trong môi trường sản xuất.
- **Không gian biến thể (Variants):** Phân định 8 biến thể kiến trúc (V1–V8). Trong đó, nhóm cốt lõi V1–V4 áp dụng cho mô hình huấn luyện từ đầu (train from scratch), phân biệt bởi hình thức phục vụ dự đoán (Inference Service độc lập vs. Inference Engine Pool dùng chung) và phương thức tái huấn luyện (Manual vs. Continuous Training). Các biến thể V5–V8 tương ứng áp dụng cho mô hình nạp sẵn (pre-trained/fine-tuned).

Khung tham chiếu trên được sử dụng như một chuẩn mực đánh giá cấu trúc và phân tích khoảng trống (gap analysis), giúp định hình hướng phát triển học thuật thay vì xem xét như một danh mục kiểm tra cứng nhắc.

1.2 Phương pháp thẩm định mã nguồn

Đánh giá được thực hiện trực tiếp trên mã nguồn, schema cơ sở dữ liệu, đặc tả hạ tầng Kubernetes/Docker và các bộ kiểm thử tự động của repository. Các luồng nghiệp vụ chính được rà soát bao gồm: (1) upload/build artifacts, (2) training execution & tracking, (3) model serving & event stream, (4) model registry & deployment, và (5) drift monitoring workflow. Một thành phần được ghi nhận là “Thiếu” thể hiện rằng nền tảng chưa cung cấp contract hoặc module cài đặt sẵn trong hệ thống quản trị, không hàm ý người dùng bị giới hạn khi tự định nghĩa logic trong mã nguồn mô hình riêng.

2 Kết luận điều hành (Executive Summary)

Tổng thể mã nguồn xác nhận repository là một **nền tảng MLOps PaaS mạnh mẽ ở khâu vận hành và triển khai mô hình (Model Operations)**, nhưng chưa hoàn thiện năng lực **tự thích ứng và bảo trì mô hình khép kín (Closed-Loop Continuous Training)**. Điểm mạnh nổi bật nằm ở kiến trúc phân tầng rõ ràng (Control Plane vs. Data Plane vs. Execution Plane), tính bất biến của phiên bản mô hình, tính đa dạng của backend huấn luyện và kênh thu thập sự kiện suy luận. Ngược lại, điểm nghẽn lớn nhất nằm ở sự thiếu vắng vòng lặp phản hồi nhân thực tế, thiếu cơ chế giám sát chất lượng/hiệu năng suy giảm và chưa có trí tuệ ra quyết định (decision intelligence) giữa khâu cảnh báo và kích hoạt tái huấn luyện.

Table 1: Đánh giá tổng hợp năng lực hệ thống theo khung kiến trúc tham chiếu.

Trục kiến trúc	Mức độ	Nhận định tổng quan
Nền tảng & Phân tầng	7/10	Phân tách rõ ràng giữa Control, Data và Execution Plane; phân quyền tenant chuẩn mực.
Lưu trữ & Quản lý phiên bản	7/10	Quản lý artifact, digest image và snapshot huấn luyện bất biến; thiếu Feedback DB.
Huấn luyện & CI/CD	7/10	Hỗ trợ đa backend (Docker/Argo/Kubeflow), đóng gói tự động; thiếu Evaluation Gate tự động.
Suy luận & Quan sát	6/10	Gateway serving tốt, thu thập event stream ổn định; chưa đo lường performance thực tế.
Vòng đời bảo trì khép kín	4/10	Tự động kích hoạt DriftRun khi đủ mẫu; chưa có cơ chế chặn đoán nguyên nhân và CT policy.
Quản trị & Stakeholder	4/10	Có xác thực JWT/API-Key và audit log; chưa có luồng phê duyệt (approval) cho bảo trì mô hình.

Xác định biến thể kiến trúc hiện tại: Đối chiếu với phân loại của Amou Najafabadi *et al.* [1], hệ thống hiện đáp ứng trọn vẹn đặc trưng của **Biến thể V1 (Inference Service + Manual Retraining)**: dịch vụ model-packager đóng gói mô hình thành container độc lập, task deployment đẩy lên hạ tầng production, và model-server định tuyến phục vụ dự đoán. Việc tái huấn luyện hoàn toàn phụ thuộc vào thao tác thủ công của kỹ sư ML. Mục tiêu của đề tài là nghiên cứu và nâng cấp hệ thống từ biến thể V1 lên **Biến thể V3 (Continuous Training Pipeline)** có tích hợp cơ chế nhận thức suy giảm thích ứng.

3 Đối chiếu cấu trúc kiến trúc — Mapping 39 thành phần

Phần này ánh xạ chi tiết 39 thành phần chức năng của khung kiến trúc tham chiếu [1] với hiện trạng mã nguồn thực tế của repository, chia theo 6 nhóm chức năng. Sơ đồ Hình 1 mô tả mối quan hệ tương tác giữa 6 nhóm nền tảng và làm nổi bật vòng lặp ra quyết định (Decision Loop) đề xuất bổ sung.

3.1 Data Curation

Table 2: Ánh xạ nhóm Data Curation.

Thành phần	Mức độ	Bằng chứng trong mã nguồn	Khoảng trống kiến trúc / Hướng phát triển
Data Collector	Một phần	Workspace assets hỗ trợ upload mã/dữ liệu; TrainingJob nhận data_snapshot_uri.	Chưa có đường ống thu nạp dữ liệu tự động (automated data ingestion) từ nguồn bên ngoài.
Data Source	Một phần	Hỗ trợ nạp dataset qua workspace; asset tham chiếu (reference asset) cho drift.	Nền tảng chưa quản trị kết nối trực tiếp tới các nguồn dữ liệu ngoại vi (APIs, Streaming, DBs).
Data Preprocessor	Thiếu	Tiền xử lý dữ liệu được thực thi trực tiếp trong mã người dùng tại entry point.	Chưa có pipeline tiền xử lý và chuẩn hóa dữ liệu được quản lý ở cấp độ nền tảng (platform-managed).

Thành phần	Mức độ	Bằng chứng trong mã nguồn	Khoảng trống kiến trúc / Hướng phát triển
Data Quality Checker	Thiếu	Chưa có module hiện thực sẵn trong nền tảng.	Khoảng trống trọng yếu; cần thiết để ngăn chặn việc tái huấn luyện trên dữ liệu sai hỏng/lỗi schema.
Data Labeler	Thiếu	Chưa có luồng gán nhãn hoặc tích hợp hệ thống annotation.	Cần thiết cho vòng lặp tiếp nhận nhãn trễ (delayed-label feedback loop).

3.2 Storage & Versioning

Table 3: Ánh xạ nhóm Storage & Versioning.

Thành phần	Mức độ	Bằng chứng trong mã nguồn	Khoảng trống kiến trúc / Hướng phát triển
Data Catalog	Thiếu	Chưa có metadata catalog quản lý danh mục dataset tập trung.	Cần thiết nhằm truy xuất toàn diện nguồn gốc dữ liệu phục vụ mô hình (data → model lineage).
Dataset Repository	Một phần	S3 lưu trữ các snapshot dữ liệu huấn luyện (data_snapshot_uri); workspace assets.	Dữ liệu chưa được mô hình hóa thành thực thể phiên bản độc lập; lưu trữ dạng snapshot tĩnh.
Raw Data Store	Một phần	S3 lưu trữ raw/reference assets; production logs lưu trong PostgreSQL.	Chưa phân tách triệt để giữa tầng lưu trữ dữ liệu thô (raw), sơ chế (processed) và dữ liệu chuẩn (curated).
Feature Store	Thiếu	Chưa có module hiện thực trong hệ thống.	Các đặc trưng hiện được tính toán trực tiếp trong mã nguồn người dùng.
Code Repository	Có	Quản lý code_snapshot_uri bất biến trong TrainingJob; liên kết Git repo.	Đã đáp ứng trọn vẹn yêu cầu quản lý phiên bản mã nguồn huấn luyện.
Model Repository	Có	ModelVersion + ModelArtifact + ModelMetric trong ứng dụng registry; phiên bản bất biến, metrics/params summary, artifacts.	Đạt chuẩn mực cao; đây là năng lực nền tảng cốt lõi của hệ thống.
Artifact Repository	Có	S3 + thực thể ModelArtifact lưu trữ container image và artifacts theo phiên bản; checksum cố định.	Đã đáp ứng tốt cho biến thể V1; cần mở rộng liên kết với cổng thẩm định candidate.
ML Metadata Repository	Có	Tracking TrainingJob (JSON), TrainingOutput, TrainingJobEvent, RegistryEvent; tích hợp MLflow.	Đã hoàn thiện ở mức nền tảng; cần bổ sung thêm environment lineage và configuration lineage.

Thành phần	Mức độ	Bằng chứng trong mã nguồn	Khoảng trống kiến trúc / Hướng phát triển
Feedback Database	Thiếu	Schema PostgreSQL có các trường runtime nhưng chưa có Feedback API/Store cho ground truth.	Khoảng trống then chốt —cần xây dựng bảng Feedback liên kết trực tiếp với prediction_id.
Predictions Storage	Có	Bảng paas_production_logs lưu trữ log suy luận phân vùng theo tenant/project/version.	Đã có lưu trữ, nhưng cần bổ sung các trường runtime (confidence, latency, status) vào event stream.

3.3 ML Training

Table 4: Ảnh xạ nhóm ML Training.

Thành phần	Mức độ	Bằng chứng trong mã nguồn	Khoảng trống kiến trúc / Hướng phát triển
Feature Engineering Pipeline	Một phần	Biến đổi đặc trưng nằm trong mã người dùng; chưa có pipeline quản lý tập trung.	Cần chuẩn hóa biến đổi và phiên bản hóa đặc trưng khi logic feature ảnh hưởng tới CT.
ML Experiment Pipeline	Có	TrainingJob hỗ trợ entry point, snapshot mã/dữ liệu, tích hợp MLflow; Docker hoặc Argo/Kubeflow.	Nền tảng thực thi thử nghiệm hoạt động tin cậy và linh hoạt.
Continuous Training Pipeline	Thiếu	Chưa có luồng tự động hóa tái huấn luyện khép kín.	Trọng tâm nghiên cứu cốt lõi của đề tài.
Model Evaluator	Một phần	Trích xuất metrics qua MLflow/TrainingOutput; chưa có cổng thẩm định đối kháng tự động.	Cần xây dựng thực thể EvaluationGate phục vụ so sánh Champion–Candidate.
Fine-Tuning Module	Thiếu	Chưa hỗ trợ quy trình tinh chỉnh mô hình nạp sẵn chuyên biệt.	Thành phần mở rộng cho các biến thể V5–V8 trong tương lai.

3.4 CI/CD

Table 5: Ảnh xạ nhóm CI/CD.

Thành phần	Mức độ	Bằng chứng trong mã nguồn	Khoảng trống kiến trúc / Hướng phát triển
ML Component Builder	Có	Dịch vụ model-packager đóng gói container image từ training artifacts; theo dõi trạng thái, digest.	Đã hoàn thiện vững chắc cho quy trình đóng gói tự động.
ML Component Deployer	Có	Thực thể Deployment, Endpoint, Kustomize/GitOps manifests; Celery task orchestration.	Đã đáp ứng tốt việc triển khai containerized component lên hạ tầng.

Thành phần	Mức độ	Bằng chứng trong mã nguồn	Khoảng trống kiến trúc / Hướng phát triển
ML Model Deployer	Thiếu	Chưa hỗ trợ nạp mô hình động vào một Inference Engine Pool dùng chung.	Chỉ áp dụng khi mở rộng sang biến thể V2/V4.
ML Pipeline Builder	Một phần	Cấu hình Argo Workflows / Kubeflow pipeline manifests có sẵn trong hệ thống.	Đóng gói pipeline huấn luyện chuẩn hóa qua Argo templates, không tự xây dựng orchestrator mới.
ML Pipeline Deployer	Một phần	Kích hoạt qua Celery tasks và Kubernetes CRDs.	Kết nối RetrainingRequest với Argo Events để kích hoạt pipeline tự động có điều kiện.

3.5 Inference

Table 6: Ánh xạ nhóm Inference.

Thành phần	Mức độ	Bằng chứng trong mã nguồn	Khoảng trống kiến trúc / Hướng phát triển
Inference Service	Có	Model-server gateway + ML/DL serving workers; định tuyến theo phiên bản; xác thực JWT/API-Key; Prometheus metrics.	Nền tảng phục vụ suy luận hoạt động ổn định và tin cậy (đặc trưng V1).
Inference Engine Pool	Thiếu	Không sử dụng mô hình engine pool nạp động đa mô hình.	Không thuộc phạm vi kiến trúc hướng tới (V1/V3).
Runtime Model Monitor	Một phần	Prometheus theo dõi latency/request count; Redpanda event stream; Evidently tính toán data drift.	Còn thiếu: giám sát hiệu năng thực tế (F1/Recall trên nhãn trễ) và trôi dạt phân phối dự đoán.
Trigger	Một phần	Transactional Outbox tạo DriftRun tự động khi đủ ngưỡng số lượng bản ghi tích lũy.	Hiện chỉ kích hoạt tính toán drift, chưa kết nối tới luồng chẩn đoán hay quyết định CT.
Model Comparison Runner	Thiếu	Giao diện so sánh mô hình hiện là placeholder, chưa có engine so sánh đối kháng thực tế.	Khoảng trống trọng yếu —cần thiết để thẩm định candidate trước khi triển khai.
Decision Processor	Thiếu	Chưa có khối logic ra quyết định bảo trì mô hình.	Sẽ được hiện thực hóa qua module Chẩn đoán và RetrainingRequest.
XAI Module	Thiếu	Chưa tích hợp module giải thích mô hình (Explainable AI).	Thành phần mở rộng nghiên cứu, không thuộc phạm vi cốt lõi của đề tài.

3.6 Infrastructure & Supporting Services

Table 7: Ảnh xạ nhóm Infrastructure & Supporting Services.

Thành phần	Mức độ	Bằng chứng trong mã nguồn	Khoảng trống kiến trúc / Hướng phát triển
Resource Manager	Một phần	TrainingJob quản lý cấu hình tài nguyên (vcpu, memory_mb, GPU); Kubernetes resource limits.	Còn thiếu: cơ chế quan sát chi phí tính toán (cost observability) và metrics GPU chi tiết.
Communication Middleware	Có	Redpanda (tương thích Kafka) truyền nhận sự kiện suy luận; EventOutbox; Celery + Redis cho hàng đợi tác vụ.	Đạt chuẩn mực cao về tính ổn định và khả năng mở rộng.
Container Orchestrator	Có	Docker Compose cho môi trường phát triển cục bộ; Kubernetes/K3s cho môi trường sản xuất.	Đã đáp ứng trọn vẹn yêu cầu điều phối container.
Workflow Orchestrator	Có	Celery xử lý tác vụ bất đồng bộ; Argo Workflows/Kubeflow điều phối huấn luyện quy mô lớn; GitOps.	Hệ thống điều phối quy trình hoạt động hoàn chỉnh và linh hoạt.
Log Manager	Có	Bảng paas_production_logs; nhật ký TrainingJobEvent; RegistryEvent; Transactional Outbox.	Hạ tầng quản lý log phân tầng và đảm bảo tính nhất quán dữ liệu.
API Gateway	Có	Model-server FastAPI gateway; Traefik reverse proxy; Django REST framework APIs tại Control Plane.	Đã hoàn thiện tốt khả năng định tuyến và kiểm soát truy cập an toàn.
MLOps User Interaction Manager	Một phần	Giao diện người dùng React/Vite; dashboard theo dõi drift; giao diện quản lý training/deployment.	Cần bổ sung dòng thời gian bằng chứng, hộp thư duyệt yêu cầu và giao diện so sánh mô hình.

3.7 Tổng hợp kết quả ánh xạ 39 thành phần

Đối chiếu toàn diện 39 thành phần kiến trúc theo khung tham chiếu chuẩn mực của Amou Najafabadi *et al.* [1], hệ thống hiện đáp ứng trọn vẹn 14 thành phần (35.9%), đáp ứng một phần 10 thành phần (25.6%) và còn thiếu 15 thành phần (38.5%). Bảng 8 và Hình 1 tổng hợp chi tiết mức độ đáp ứng theo từng nhóm chức năng:

- **Nhóm thể mạnh nền tảng (Infrastructure & Supporting, Storage & Versioning):** Đạt mức độ hoàn thiện cao nhất, cung cấp đầy đủ hạ tầng container (Kubernetes/K3s), messaging (Redpanda/Kafka), điều phối tác vụ (Celery) và quản lý phiên bản mô hình/artifact bất biến.
- **Nhóm trọng tâm cần nghiên cứu (Data Curation, Inference & ML Training):** Là khu vực tồn tại các khoảng trống lớn nhất về vòng lặp phản hồi nhân thực tế, chẩn đoán nguyên nhân suy giảm đa tín hiệu, công thẩm định đối kháng candidate–champion và điều phối lưu lượng shadow/canary. Đây chính là không gian đóng góp khoa học cốt lõi của đề tài nhằm đưa hệ thống tiến hóa lên biển thể Continuous Training thích ứng.

Table 8: Tổng hợp mức độ đáp ứng 39 thành phần chức năng theo từng nhóm.

Nhóm thành phần	Có	Một phần	Thiếu	Nhận định kiến trúc
Data Curation (5)	0	2	3	Nhóm yếu nhất; cần bổ sung Data Quality Checker và Feedback cho CT.
Storage & Versioning (10)	5	2	3	Model/Artifact Repository mạnh mẽ; thiếu Feedback Database liên kết.
ML Training (5)	1	2	2	ML Experiment Pipeline tốt; Continuous Training là trọng tâm phát triển.
CI/CD (5)	2	0	3	Đóng gói/triển khai tốt cho V1; thiếu pipeline builder/deployer cho V3.
Inference (7)	1	2	4	Serving gateway ổn định; thiếu Model Comparison Runner và performance monitoring.
Infrastructure & Supporting (7)	5	2	0	Hạ tầng nền tảng hoàn thiện; cần bổ sung giao diện tương tác nâng cao.
Tổng cộng (39)	14	10	15	Đánh giá bao quát đủ 39 thành phần nhằm minh bạch phạm vi và định vị rõ ranh giới nghiên cứu.




Figure 1: Bản đồ sáu nhóm component của paper và decision loop đề xuất cho repo. Màu xanh biểu diễn các nhóm nền tảng; màu cam là lớp cần xây dựng để chuyển từ V1 sang continuous training.

3.8 Nền tảng kiến trúc hiện hữu có giá trị kế thừa

- **Phân tách ranh giới các mặt phẳng (Planes Boundary):** Hệ thống phân định rõ ràng giữa Control Plane (điều phối vòng đời, xác thực đa tenant), Data Plane (phục vụ suy luận với độ trễ thấp) và Execution Plane (huấn luyện phi tập trung qua Docker hoặc Argo/Kubeflow). Trạng thái nghiệp vụ được bảo đảm tính nhất quán bền vững trên PostgreSQL và S3.
- **Tính bất biến của phiên bản mô hình (Version Immutability):** Mọi build thành công đều gắn liền với digest container image và artifact checksum cố định. Khái niệm Model Alias cho phép thăng cấp (promotion) hoặc thu hồi (rollback) linh hoạt mà không làm biến đổi lịch sử phiên bản.
- **Kênh truyền nhận sự kiện sản xuất an toàn (Production Event Pipeline):** Gateway truyền dữ liệu suy luận có phân quyền tenant/project sang Redpanda/Kafka; dịch vụ Consumer lưu vết vào bảng `paas_production_logs` và sử dụng Transactional Outbox pattern để tạo tín hiệu kích hoạt tính toán drift an toàn.
- **Quy trình giám sát trôi dạt dữ liệu (Drift Workflow):** Hỗ trợ liên kết model version với dữ liệu tham chiếu (reference dataset); Evidently tính toán chỉ số trôi dạt; callback cập nhật trạng thái `DriftRun` dựa trên UUID và idempotency key.
- **Hạ tầng huấn luyện linh hoạt:** Thực thể `TrainingJob` hỗ trợ cấu hình tài nguyên chi tiết (vCPU, RAM, GPU), cơ chế bảo mật capabilities-based và lưu vết bất biến mã nguồn (`code_snapshot_uri`) cùng dữ liệu (`data_snapshot_uri`).

3.9 Phân tích các khoảng trống kiến trúc then chốt

Đối chiếu với yêu cầu của một hệ thống Continuous Training thích ứng, repository hiện tồn tại 6 khoảng trống cốt lõi:

1. **Hợp đồng dữ liệu sự kiện (Event Contract) chưa hoàn chỉnh:** Mặc dù schema consumer đã định nghĩa các trường `confidence`, `latency_ms`, `status_code` và `request_id`, nhưng gateway `model-server` hiện chỉ mới gửi dữ liệu features và output thô. Điểm số tự tin (`confidence`) và các thông số vận hành chưa được truyền tải vào event stream.
2. **Đứt gãy mối nối định danh dự đoán (Prediction ID Correlation):** Khóa định danh sự kiện `id` được sinh nội bộ tại gateway nhưng chưa được trả về cho phía client trong response. Do đó, client không có mã tham chiếu để gửi nhãn thực tế (ground truth) tương ứng sau này.
3. **Phạm vi giám sát dừng lại ở Data Drift:** Evidently hiện chỉ đo lường sự dịch chuyển phân phối dữ liệu đầu vào ($P(X)$), chưa hỗ trợ đánh giá chất lượng dữ liệu (data quality checks) cũng như chưa đo lường suy giảm hiệu năng thực tế ($P(Y|X)$, F1, Precision, Recall) do thiếu nhãn.
4. **Cơ chế kích hoạt thụ động (Passive Triggering):** Bảng `paas_automatic_drift_outbox` chỉ kích hoạt việc tạo một lượt chạy `DriftRun` khi tích lũy đủ số lượng bản ghi, hoàn toàn chưa có liên kết tự động tới luồng chẩn đoán hay yêu cầu tái huấn luyện.
5. **Quy trình đánh giá và thăng cấp thủ công:** Chức năng so sánh mô hình trên giao diện hiện chỉ hiển thị placeholder, thiếu một Evaluation Gate có thể tự động kiểm tra đối kháng (champion vs. candidate) trước khi quyết định triển khai.
6. **Chưa hỗ trợ phân tách lưu lượng (Traffic Splitting):** Gateway chỉ định tuyến toàn bộ 100% lưu lượng tới một phiên bản duy nhất, chưa hỗ trợ Shadow Mode (nhân bản request) hoặc Canary Rollout (chia tỉ lệ lưu lượng động).

3.10 Phân định Ranh giới Nền tảng (Platform Scope) và Phạm vi Nghiên cứu (Research Scope)

Để tránh phân tán nguồn lực vào việc phát triển hệ thống mà thiếu chiều sâu khoa học, Bảng 9 phân định rãnh mạch ranh giới giữa vai trò hạ tầng nền tảng và các cấp độ đóng góp nghiên cứu ($Q3 \rightarrow Q2 \rightarrow Q1$ Stretch):

Table 9: Phân định ranh giới giữa Hạ tầng Nền tảng và các Cấp độ Nghiên cứu.

Thành phần chức năng	Vai trò Nền tảng (Platform)	Chuẩn Q3	Mở rộng Q2	Mục tiêu Q1 Stretch
Event Pipeline & Logging	Hạ tầng thu thập	Hỗ trợ	Hỗ trợ	Hỗ trợ
Data Drift & Quality Checks	Bảng chứng vận hành	Sâu	Sâu	Sâu
Concept Drift Monitoring	Bảng chứng nghiên cứu	Sâu	Sâu	Sâu
Biểu diễn Đa bằng chứng	Cốt lõi nghiên cứu	Core	Core	Core
Chẩn đoán Nguyên nhân	Cốt lõi nghiên cứu	Core	Core	Core
Định lượng Severity & Confidence	Cốt lõi nghiên cứu	Core	Core	Core
Bộ Lựa chọn Chiến lược (Policy)	Cốt lõi nghiên cứu	Core	Core	Core
Tái huấn luyện Gia tăng / Toàn phần	Hạ tầng thực thi CT	Hỗ trợ	Sâu	Sâu
Vòng lặp Chuyên gia (HITL)	Rào chắn an toàn	Hỗ trợ	Sâu	Sâu
Tối ưu Siêu tham số (HPO)	Nhánh mở rộng	Tùy chọn	Vừa phải	Sâu
Shadow Mode & Rollback	An toàn triển khai	Hỗ trợ	Hỗ trợ	Hỗ trợ
Khái quát hóa Đa miền (Tasks)	Đánh giá thực nghiệm	2–3 tasks	Bắt buộc	Mạnh mẽ
Chẩn đoán Nhân quả (Causal)	Nghiên cứu dài hạn	Không	Tùy chọn	Core tiềm năng
Online / Adaptive Policy Learning	Nghiên cứu dài hạn	Không	Tùy chọn	Core tiềm năng

4 Đối chiếu quy trình vòng đời (56 Process Steps)

Kết quả đối chiếu quy trình khẳng định một kết luận kiến trúc quan trọng: **hệ thống đã xây dựng hoàn chỉnh hạ tầng đường ống (Ingestion Plumbing), nhưng còn thiếu hoàn toàn khối trí tuệ ra quyết định (Adaptive Decision Loop)**. Việc chỉ gắn thêm một lệnh kích hoạt tái huấn luyện đơn giản sau khi phát hiện data drift sẽ không tạo nên một hệ thống CT tin cậy, bởi vì: (1) data drift không đồng nghĩa với suy giảm hiệu năng thực tế (có thể là benign drift), và (2) việc tự động huấn luyện lại trên dữ liệu bị lỗi hoặc nhân nhiễu sẽ làm lặp lại hoặc trầm trọng hóa sai số mô hình.

Table 10: Hiện trạng triển khai các nhóm quy trình vòng đời then chốt [1].

Nhóm quy trình	Mức độ	Hiện trạng triển khai thực tế
Khởi tạo, đóng gói & đăng ký	Có	Upload code/data → build container image → đăng ký model version bất biến.
Thử nghiệm & huấn luyện	Một phần	Training job quản lý snapshot dữ liệu/mã nguồn; tracking metadata tích hợp qua MLflow.
Triển khai & phục vụ dự đoán	Có	Model build sẵn sàng được deploy; Gateway xác thực và proxy theo tenant/project/version.
Thu thập bằng chứng sản xuất	Một phần	Đã lưu vết features/prediction; cân bổ sung confidence, latency, prediction ID và feedback.
Phát hiện suy giảm (Detection)	Một phần	Đã có data drift và metrics hạ tầng; chưa chuẩn hóa prediction drift, data quality và performance.
Chẩn đoán nguyên nhân (Diagnosis)	Thiếu	Chưa có module suy luận nguyên nhân (cause candidates), đồ thị bằng chứng và giải thích.
Lựa chọn hành động & phê duyệt	Thiếu	Alert chưa chuyển đổi thành RetrainingRequest; thiếu cơ chế định tuyến Auto/Human/Engineering.
Tái huấn luyện, kiểm thử & thăng cấp	Một phần	Thực hiện thủ công; thiếu Evaluation Gate tự động, shadow/canary routing và auto-rollback.

5 Hướng phát triển: Degradation-Aware Adaptive Model Maintenance

5.1 Luận đề nghiên cứu và Định vị đóng góp

Luận đề nghiên cứu trung tâm (Central Research Thesis):

“Trôi dạt dữ liệu không đồng nghĩa với suy giảm hiệu năng mô hình, và suy giảm hiệu năng mô hình không đồng nghĩa với việc tự động tái huấn luyện trên cùng tập dữ liệu và mã nguồn là phản ứng thích hợp ($Data\ Drift \neq Model\ Degradation \neq Retraining\ Trigger$). Một sự cố suy giảm mô hình không được tự động suy ra hành vi tái huấn luyện; hành động bảo trì thích hợp phải được lựa chọn từ các bằng chứng không đồng nhất về nguyên nhân, mức độ nghiêm trọng (Severity), độ tin cậy (Confidence) và bối cảnh vận hành.”

Chuỗi xử lý khép kín mục tiêu (Closed-loop Architecture):

Production Monitoring → Multi-Evidence Extraction → Probabilistic Diagnosis → Severity + Confidence → Risk-Aware Strategy → Action Space (No-op / Incremental CT / Full CT / HITL) → Evaluation Gate → Promote / Reject

Repository MLOps PaaS hiện tại đóng vai trò là **nền tảng thực nghiệm nguồn mở (Experimental Platform)**, cung cấp hạ tầng serving, thu thập log và môi trường huấn luyện đa dạng. Đóng góp khoa học cốt lõi nằm ở việc thiết kế và kiểm chứng **Khung bảo trì mô hình thích ứng nhận thức suy giảm (Degradation-Aware Adaptive Model Maintenance Framework)**.

5.2 Câu hỏi nghiên cứu và Giả thuyết khoa học

Nghiên cứu tập trung giải quyết 3 câu hỏi nghiên cứu cốt lõi:

- RQ1 (Khả năng chẩn đoán - Diagnosis):** Việc giám sát bằng chứng đa nguồn (Multi-Evidence Monitoring) có thể phân biệt chính xác các nguyên nhân suy giảm mô hình khác nhau vượt trội so với các phương pháp dựa trên một tín hiệu đơn lẻ (Single-Signal) hay không?
- RQ2 (Lựa chọn chiến lược thích ứng - Adaptive Strategy Selection):** Chính sách lựa chọn hành động nhận thức suy giảm có thể cắt giảm số lần tái huấn luyện không cần thiết (unnecessary retraining) trong khi vẫn duy trì năng lực phục hồi mô hình phù hợp so với các chính sách tái huấn luyện chung chung (generic retraining policies) hay không?
- RQ3 (Tính vững chắc & Kết quả - Robustness & Outcome):** Khối chẩn đoán và bộ lựa chọn chiến lược đề xuất đạt mức độ vững chắc như thế nào khi đối mặt với các cấp độ nghiêm trọng khác nhau, suy giảm

hỗn hợp (mixed degradation), nhãn bị trễ (delayed labels) và bằng chứng bị nhiễu hoặc không đầy đủ?

Bốn giả thuyết khoa học (Hypotheses) phục vụ kiểm định thống kê:

- **H1:** Chính sách lựa chọn chiến lược thích ứng dựa trên nhận thức suy giảm làm giảm có ý nghĩa thống kê số lần tái huấn luyện không cần thiết so với các baseline Always Retrain và Drift-Triggered CT.
- **H2:** Khối chẩn đoán đa bằng chứng (Multi-Evidence Diagnosis) cải thiện độ chính xác phân loại nguyên nhân suy giảm so với các bộ chẩn đoán chỉ dựa trên một tín hiệu đơn lẻ.
- **H3:** Cơ chế lựa chọn chiến lược thích ứng tối ưu hóa tỷ lệ đánh đổi (trade-off) giữa năng lực phục hồi hiệu năng, chi phí tính toán và nỗ lực chuyên gia.
- **H4:** Vòng lặp chuyên gia (Human-in-the-Loop) trong các trường hợp rủi ro cao hoặc độ tin cậy thấp triệt tiêu các hành vi tự động hóa mất an toàn (unsafe automated actions).

5.3 Khung phân loại nguyên nhân cốt lõi (Core Degradation Taxonomy)

Nhằm bảo đảm tính tập trung khoa học và khả thi cho phiên bản baseline vững chắc (chuẩn Q3), hệ thống giới hạn vào **5 nhóm nguyên nhân cốt lõi (Core Degradation Classes)**:

Table 11: Hệ thống phân loại 5 nhóm nguyên nhân suy giảm cốt lõi.

Mã	Nguyên nhân (Cause)	Đặc trưng nhận diện và Phạm vi
C0	BENIGN / NO_ACTION	Trôi dạt đầu vào $P(X)$ nhẹ nhưng phân phối điều kiện $P(Y X)$ và hiệu năng thực tế ổn định; không cần can thiệp.
C1	DATA_DRIFT	Trôi dạt phân phối đầu vào kéo theo suy giảm hiệu năng thực tế có ý nghĩa thống kê trên tập nhãn xác thực.
C2	DATA_QUALITY	Vi phạm ràng buộc dữ liệu: lỗi schema, vi phạm miền giá trị, tỷ lệ missing/null tăng vọt hoặc mất tính tươi mới dữ liệu.
C3	CONCEPT_DRIFT	Mối quan hệ giữa đặc trưng và nhãn $P(Y X)$ thay đổi đột ngột; sai số tăng phân bố theo lát cắt (slice error).
C4	DATA_STALENESS	Dữ liệu huấn luyện bị lão hóa theo thời gian; độ bao phủ thời gian (temporal coverage) không còn đáp ứng thực tế.

Ghi chú phân định phạm vi: Các nhóm nguyên nhân mở rộng như CONFIG_SUBOPTIMAL, ENGINEERING_ISSUE và ARCHITECTURE_LIMITATION được xử lý như các kịch bản gây nhiễu/thử thách nâng cao (Stress scenarios) trong phần mở rộng tương lai (Q2/Q1) nhằm giữ trọn vẹn trọng tâm cho bài toán chẩn đoán suy giảm mô hình.

5.4 Định lượng Mức độ nghiêm trọng Độc lập (Independent Severity Modeling)

Mức độ nghiêm trọng (Severity) không bị đồng nhất với một ngưỡng hiệu năng đơn giản, mà được mô hình hóa thành một hàm 4 thành tố độc lập:

$$\text{Severity} = f(\text{PerformanceImpact}, \text{Scope}, \text{Persistence}, \text{Risk})$$

trong đó:

- **PerformanceImpact:** Mức suy giảm chất lượng dự đoán (ΔF_1 , ΔAUC , ΔMAE).
- **Scope:** Tỷ lệ lưu lượng hoặc phân khúc khách hàng (population slice) bị ảnh hưởng.
- **Persistence:** Số cửa sổ liên tiếp hoặc khoảng thời gian kéo dài của sự cố.
- **Risk:** Mức độ nhạy cảm và tổn thất nghiệp vụ/vận hành tiềm tàng.

Hệ thống phân tầng Severity thành 5 cấp bậc:

- S_0 (**None**): Trạng thái bình thường; biến động ngẫu nhiên trong khoảng kiểm soát.
- S_1 (**Early Warning / Low**): Biến động nhẹ, hiệu năng ổn định hoặc cảnh báo sớm từ phân phối confidence khi chưa có nhãn.
- S_2 (**Moderate**): Suy giảm hiệu năng vừa phải cục bộ (3%–8%) kèm nhãn xác thực đầy đủ.

- S_3 (**High**): Suy giảm hiệu năng $> 8\%$ trên diện rộng hoặc vi phạm chất lượng dữ liệu nghiêm trọng.
- S_4 (**Critical**): Mô hình sụp đổ hoàn toàn hoặc vi phạm guardrails an toàn vận hành sản xuất.

5.5 Ma trận Bằng chứng và Giám sát Đa nguồn (Evidence Matrix)

Hệ thống phân biệt rõ ràng các nhóm bằng chứng vận hành thay vì gộp chung thành “drift”:

Table 12: Ma trận Bằng chứng, Giám sát và Chiến lược can thiệp ứng viên.

Nguyên nhân	Bằng chứng chính (Primary)	Bằng chứng phụ (Secondary)	Cần nhân?	Chiến lược ứng viên
Data drift	PSI, KS, JS, Wasserstein	Prediction drift, Confidence drift	Không	Cập nhật dữ liệu + Incremental/Full CT
Data quality	Missing rate, Schema, Range, Freshness, Duplicate	Suy giảm hiệu năng	Không	Can thiệp kỹ thuật (DATA_ENGINEERING)
Concept drift	Biến động quan hệ $P(Y X)$, Slice error, Class recall shift	Hiệu năng thực tế giảm, Trôi dạt $P(X)$ thấp, Calibration error	Bắt buộc	Thu thập nhãn mới + Phân tích lát cắt / HITL
Data staleness	Tuổi dữ liệu (Data age), Độ phủ nhãn, Temporal coverage	Trôi dạt Train-vs-Prod	Tùy chọn	Cập nhật snapshot + Full CT
Benign / Stable	Không có bằng chứng suy giảm có hại	Hiệu năng thực tế ổn định	Không	NO_OP / OBSERVE

5.6 Khối Chẩn đoán Đa bằng chứng và Lựa chọn Chiến lược (Multi-Evidence Diagnosis & Strategy Selection)

5.6.1 Ba cấp độ phương pháp chẩn đoán đối chứng

Để kiểm chứng đóng góp khoa học, đề tài thiết lập và đối sánh 3 phương pháp chẩn đoán:

- **D1 – Single-Signal Detector (Baseline):** Suy luận nguyên nhân suy giảm chỉ dựa vào một chỉ số trôi dạt duy nhất (ví dụ: khoảng cách Wasserstein hoặc PSI).
- **D2 – Rule-Based Multi-Signal Diagnosis (Heuristic Baseline):** Tập luật điều kiện kết hợp ngưỡng cứng (thể hiện qua Thuật toán 5.6.3).
- **D3 – Proposed Multi-Evidence Weighted Diagnosis (Proposed Method):** Mô hình tổng hợp bằng chứng đa nguồn có trọng số và hiệu chuẩn xác suất độc lập đa nhãn (Multi-Label Independent Probability):

$$\text{Score}(C_i) = \sum_j w_{ij} \phi_j(E_j) \implies P(C_i | E) = \sigma(\text{Score}(C_i)) = \frac{1}{1 + e^{-\text{Score}(C_i)}}$$

trong đó $\phi_j(E_j)$ là hàm chuẩn hóa từng nhóm bằng chứng E_j , w_{ij} là ma trận trọng số tương quan giữa bằng chứng và nguyên nhân, và $\sigma(\cdot)$ là hàm kích hoạt Sigmoid độc lập. Khác với hàm Softmax vốn ép buộc các lớp phải loại trừ lẫn nhau ($\sum_i P(C_i | E) = 1$), hàm Sigmoid cho phép mô hình hóa chính xác các sự cố suy giảm hỗn hợp (Mixed Causes) khi nhiều nguyên nhân thực tế cùng đồng thời xuất hiện (ví dụ: vừa có trôi dạt dữ liệu vừa vi phạm chất lượng dữ liệu).

5.6.2 Cấu trúc dữ liệu chẩn đoán hỗ trợ nguyên nhân hỗn hợp (Mixed Cause Schema)

```
{
  "event_id": "deg_evt_8f1a2c",
  "cause_probabilities": {
    "DATA_DRIFT": 0.82,
    "DATA_QUALITY": 0.76,
    "CONCEPT_DRIFT": 0.11,
    "DATA_STALENESS": 0.05,
    "BENIGN": 0.02
  },
  "primary_cause": "DATA_DRIFT",
  "secondary_causes": ["DATA_QUALITY"],
  "severity": "S3_HIGH",
  "confidence": 0.82,
  "recommended_action": "FULL_CT",
  "action_constraints": { "cooldown_passed": true, "budget_ok": true }
}
```

5.6.3 Thuật toán heuristic đối chứng (Baseline D2)

Dưới đây là đặc tả thuật toán heuristic D2 đóng vai trò đường cơ sở so sánh:

Thuật toán 1 (Baseline D2): Chẩn đoán heuristic dựa trên tập luật ngưỡng cứng

Đầu vào (Input): Thực thể EvidenceWindow $E = \{d_{\text{drift}}, q_{\text{quality}}, \Delta_{\text{perf}}, \Delta_{\text{conf}}, \Delta_{\text{cond}}, r_{\text{labels}}, n, CI_{\text{perf}}, t_{\text{age}}\}$ với Δ_{cond} là chỉ số biến động quan hệ có điều kiện (slice error rate, class recall drift, feature-target correlation change).

Bước 1 (Kiểm định chất lượng dữ liệu):

If $q_{\text{quality}} < \theta_{\text{quality}}$ then Return Output(DATA_QUALITY, Sev: S_3 , Act: DATA_ENGINEERING)

Bước 2 (Kiểm tra độ phủ nhãn):

If $r_{\text{labels}} < r_{\text{min}}$ or $n < n_{\text{min}}$ then

If Δ_{conf} lệch chuẩn có ý nghĩa then Return Output(INSUFFICIENT_DATA, Sev: S_1 , Act: NO_OP_HOLD)

Else Return Output(BENIGN, Sev: S_0 , Act: NO_OP)

Bước 3 (Kiểm định trôi dạt có hại):

If $d_{\text{drift}} > \theta_{\text{drift}}$ and $\Delta_{\text{perf}} < \theta_{\text{perf}}$ then

If $|\Delta_{\text{perf}}| > 0.08$ then Sev $\leftarrow S_3$; Act $\leftarrow$ FULL_CT

Else Sev $\leftarrow S_2$; Act $\leftarrow$ INCREMENTAL_CT

If (Cooldown OK $\wedge$ Budget OK) then Return Output(DATA_DRIFT, Sev: Sev, Act: Act)

Else Return Output(DATA_DRIFT, Sev: Sev, Act: HITL)

Bước 4 (Trôi dạt lành tính):

If $d_{\text{drift}} > \theta_{\text{drift}}$ and $|\Delta_{\text{perf}}| \approx 0$ then Return Output(BENIGN, Sev: S_1 , Act: NO_OP)

Bước 5 (Ứng viên Dịch chuyển khái niệm – Concept Drift Candidate):

If $\Delta_{\text{perf}} < \theta_{\text{perf}}$ and $d_{\text{drift}} \leq \theta_{\text{drift}}$ and $q_{\text{quality}} \geq \theta_{\text{quality}}$ then

If $\Delta_{\text{cond}} > \theta_{\text{cond}}$ (có bằng chứng biến động quan hệ lát cắt/lech phân phối nhãn) then

Return Output(CONCEPT_DRIFT, Sev: S_3 , Act: HITL)

Else Return Output(UNRESOLVED_DEGRADATION, Sev: S_2 , Act: HITL)

Mặc định (Fallback): Return Output(MIXED_AMBIGUOUS, Sev: S_2 , Act: HITL)

Ghi chú khoa học: Sự cố suy giảm hiệu năng khi trôi dạt đầu vào thấp ($d_{\text{drift}} \leq \theta_{\text{drift}}$) không được tự động quy kết là Concept Drift nếu thiếu bằng chứng trực tiếp về quan hệ điều kiện/nhãn (như slice error, class recall shift). Trường hợp thiếu bằng chứng rõ ràng được định danh là UNRESOLVED để tránh chẩn đoán sai lệch do nhiễu nhãn (label noise), lão hóa dữ liệu (staleness), lệch lấy mẫu hoặc biến ẩn.

5.6.4 Không gian hành động cốt lõi (Core Action Space)

Khối Strategy Selector ánh xạ ($P(\text{Cause} \mid E)$, Severity, Confidence) thành 4 hành động cốt lõi:

$$\text{Action Space} \in \{\text{NO_OP}, \text{INCREMENTAL_CT}, \text{FULL_CT}, \text{HITL}\}$$

(kèm theo nhánh xử lý kỹ thuật phụ trợ DATA_ENGINEERING khi có sự cố chất lượng dữ liệu).




Figure 2: Workflow degradation-aware: Trục dọc thể hiện pipeline tự động hóa khép kín; các nhánh ngang thể hiện chốt an toàn và điểm can thiệp của con người/kỹ thuật khi thiếu bằng chứng.

5.7 Chiến lược xử lý nhãn trễ (Delayed-Label Handling Strategy)

Nhãn thực tế thường có độ trễ lớn so với thời điểm suy luận. Hệ thống đề xuất 5 nguyên tắc xử lý nhãn trễ:

1. **Chuỗi liên kết mã định danh dự đoán (End-to-end Prediction ID):** Gateway model-server tạo mã định danh duy nhất (prediction_id) và trả về cho client trong HTTP response, đồng thời gắn kèm mã này vào event stream lưu trữ. Client sử dụng chính prediction_id để gửi nhãn thực tế qua Feedback API. Đây là **điều kiện tiên quyết** để thực hiện phép join giữa dự đoán và nhãn thực tế.
2. **Cửa sổ trượt gắn mốc thời gian nhãn (Watermark-based Sliding Window):** Phép tính toán hiệu năng chỉ được thực hiện trên cửa sổ thời gian $[t - W, t]$ khi tỷ lệ phủ nhãn đạt ngưỡng tin cậy tối thiểu:

$$r_{\text{labels}} = \frac{|\text{Dự đoán đã có nhãn}|}{|\text{Tổng số lượt dự đoán}|} \geq r_{\text{min}}$$

Nếu $r_{\text{labels}} < r_{\text{min}}$, hệ thống ghi nhận trạng thái chưa đủ nhãn (INSUFFICIENT_LABELS) và tuyệt đối không nội suy hiệu năng giả định để auto-retrain.

3. **Chỉ số đại diện khi thiếu nhãn (Proxy Signals):** Khi nhãn chưa sẵn sàng, hệ thống dựa vào các tín hiệu đại diện: độ trôi dạt phân phối đầu ra $P(\hat{Y})$, độ dịch chuyển điểm tự tin (calibrated confidence drift) và biến động độ trễ để phát cảnh báo sớm, không dùng để kích hoạt CT trực tiếp.
4. **Phân tầng độ tin cậy của nhãn (Label Trust Levels):** Mỗi bản ghi nhãn phản hồi đều lưu kèm nguồn thu thập (label_source) và mức độ tin cậy (trust_level), ngăn ngừa việc trộn lẫn nhãn nhiễu vào dữ liệu huấn luyện mới.
5. **Ước lượng thống kê với độ phủ nhãn một phần:** Khi chỉ có một phần dự đoán được gán nhãn, hiệu năng được tính toán kèm khoảng tin cậy 95% (CI_{perf}). Cổng quyết định chỉ kích hoạt CT khi cận dưới của khoảng tin cậy xác nhận sự suy giảm thực sự.

5.8 Mô hình dữ liệu trạng thái (Minimal State Model)

Để hiện thực hóa vòng lặp khép kín, Control Plane bổ sung 8 thực thể dữ liệu bất biến:

Table 13: Các thực thể dữ liệu cốt lõi bổ sung vào Control Plane.

Thực thể (Entity)	Thuộc tính then chốt	Mục đích kiến trúc & Nghiệp vụ
PredictionRecord	prediction_id, request_id, tenant, project, version, timestamp, features, prediction, confidence, latency, status	Ghi nhận từng giao dịch suy luận và thiết lập khóa liên kết (correlation key) cho dữ liệu phản hồi.
Feedback	feedback_id, prediction_id, ground_truth, label_timestamp, label_source, trust_level, correction_version	Lưu vết nhãn thực tế trả về từ client; hỗ trợ nhiều lượt phản hồi và đính chính nhãn (correction).
EvidenceWindow	model_version, window_start, window_end, baseline_ref, metric_values (drift, quality, perf, conf, staleness), slices, label_coverage, policy_version	Lưu trữ bằng chứng vận hành bất biến theo cửa sổ thời gian phục vụ chẩn đoán và kiểm toán.
DegradationEvent	evidence_window_ids, severity, affected_component, deduplication_key, status, created_at	Chuẩn hóa sự kiện cảnh báo suy giảm với tính chất bất biến và chống trùng lặp (idempotency).

Thực thể (Entity)	Thuộc tính then chốt	Mục đích kiến trúc & Nghiệp vụ
Diagnosis	degradation_event_id, cause_probabilities (JSON), primary_cause, secondary_causes, severity_level, top_confidence, explanation	Tách biệt tường minh khâu suy luận nguyên nhân gốc rễ khỏi khâu phát hiện cảnh báo thô.
RetrainingRequest	diagnosis_id, strategy (incremental/full/hitl/eng), data_snapshot_uri, config_version, budget_limit, cooldown_until, status, approved_by	Đơn vị điều phối vòng đời tái huấn luyện thay thế cho việc gọi trực tiếp training job từ drift run.
EvaluationGate	candidate_version, champion_version, offline_metrics, calibration_score, latency_p95, error_rate, data_quality_passed, decision (pass/fail/hold)	Cổng thẩm định đối kháng nghiêm ngặt trước khi cho phép mô hình ứng viên tiếp cận môi trường sản xuất.
TrafficExperiment	experiment_type (shadow/canary), candidate_version, champion_version, hash_seed, weight_schedule, guardrails, current_weight, rollback_reason	Điều phối và ghi nhận toàn bộ quá trình thử nghiệm lưu lượng thực tế và cơ chế thu hồi tự động.

Một prediction có thể chưa có label hoặc có nhiều lần label/correction; vì vậy PredictionRecord và Feedback nên là hai bảng có quan hệ một-nhiều, kèm unique/idempotency constraint cho nguồn feedback và version correction.

6 Ranh giới tự động hoá và Quy trình kiểm thử thăng cấp

Table 14: Ma trận phân định ranh giới tự động hóa (Auto vs. Human vs. Engineering).

Cấp độ tự động	Quyền hạn của hệ thống	Ranh giới cấm tự động (Cần con người/CI)
Observe / No Action	Ghi nhận sự kiện, tăng tỷ lệ lấy mẫu, theo dõi cửa sổ tiếp theo.	Tuyệt đối không kích hoạt huấn luyện (tránh training storm).
Conditional Auto CT	Snapshot dữ liệu được phê duyệt, kích hoạt huấn luyện, kiểm thử qua EvaluationGate và đăng ký candidate.	Không tự ý thay đổi định nghĩa nhãn, cấu trúc feature, mã nguồn hay kiến trúc mô hình.
Human-approved CT	Chuẩn bị đầy đủ báo cáo chẩn đoán, vết nguồn gốc (lineage) và kế hoạch huấn luyện ứng viên.	Không tự quyết định đánh đổi rủi ro kinh doanh hoặc tiếp tục khi nhãn mâu thuẫn.
Engineering Incident	Tạo issue cảnh báo kèm bằng chứng audit trail, chuyển giao đội ngũ kỹ thuật.	Không tự can thiệp chỉnh sửa pipeline, dependency thư viện, mã ETL hay hạ tầng runtime.

6.1 Kiến trúc thử nghiệm lưu lượng thực tế (Shadow & Canary Architecture)

Quy trình thăng cấp (promotion) trong kiến trúc đề xuất tuân thủ phương pháp kiểm định đa tầng lũy tiến thay vì hoán đổi trực tiếp sau huấn luyện:

1. **Chế độ nhân bản lưu lượng (Shadow Mode - Phase 5a):** Mô hình ứng viên (Candidate) nhận một bản sao lưu lượng thực tế từ gateway mà không làm ảnh hưởng tới phản hồi trả về người dùng (Champion vẫn trả response). Dự đoán của candidate được ghi nhận độc lập vào `paas_shadow_logs` để phục vụ so sánh đối kháng trên cùng request ID.
2. **Chế độ lưu lượng tăng dần (Canary Rollout - Phase 5b):** Định tuyến lưu lượng thực tế dựa trên băm nhất quán (consistent hashing) theo khóa phân nhóm ổn định (User/Session ID). Tỷ lệ lưu lượng được nâng dần theo các mốc $5\% \rightarrow 10\% \rightarrow 25\% \rightarrow 50\% \rightarrow 100\%$ khi và chỉ khi thỏa mãn đầy đủ các chỉ số rào chắn an toàn (Guardrails).
3. **Tiêu chí rào chắn an toàn (Guardrail Evaluation):** Đánh giá liên tục trên cửa sổ trượt có kiểm định thống kê:
 - Tỷ lệ lỗi (Error rate) của Candidate $\leq$ Champion $+\epsilon$
 - Độ trễ p95 của Candidate $\leq$ Champion $\times 1.2$
 - Khoảng cách phân phối dự đoán (KL-Divergence) $\leq \theta_{\text{dist}}$
 - Hiệu năng thực tế (khi có nhãn) của Candidate $\geq$ Champion $-\delta$
4. **Thu hồi tự động (Automated Rollback):** Tự động ngắt toàn bộ lưu lượng của Candidate và chuyển đổi Blue-Green về Champion cũ khi vi phạm guardrail trong k cửa sổ liên tiếp, đồng thời lưu vết `rollback_reason` vào thực thể `TrafficExperiment`.

Hình 3 mô tả trực quan quy trình kiểm định thăng cấp lũy tiến này.




Figure 3: Protocol champion–challenger đề xuất: Trực dọc thể hiện các tầng kiểm thử lũy tiến (Offline Gate → Shadow → Canary → Full Promotion); nhánh ngang thể hiện điểm dừng an toàn và cơ chế rollback tự động.

7 Lộ trình hiện thực hoá và Kế hoạch nghiên cứu phân tầng (Q3 → Q2 → Q1)

Lộ trình nghiên cứu được thiết kế theo nguyên tắc phân tầng lũy tiến (Graduation Ladder), cho phép đóng gói một kết quả hoàn chỉnh tại chuẩn ****Q3 (Baseline vững chắc)****, mở rộng nâng cao lên ****Q2 (Nghiên cứu chuyên sâu)**** và đặt mục tiêu dài hạn ****Q1 (Đột phá khoa học)**** mà không cần viết lại kiến trúc từ đầu.

7.1 Khung phân tầng mục tiêu nghiên cứu (Research Maturity Levels)

Bảng 15 tóm lược câu hỏi khoa học, phương pháp cốt lõi và tiêu chí hoàn thành theo từng cấp độ trưởng thành nghiên cứu:

Table 15: Lộ trình phân tầng mục tiêu nghiên cứu theo cấp độ trưởng thành.

Cấp độ	Câu hỏi khoa học	Phương pháp cốt lõi	Phạm vi	Tiêu chí hoàn thành (Exit Criterion)
Nền tảng hiện hữu	Hệ thống có thể hỗ trợ thu thập và thực thi CT khép kín không?	Nền tảng MLOps PaaS mã nguồn mở	Rộng	Nền tảng vận hành ổn định, thông suốt luồng log và pipeline.
Cấp độ Q3 (Baseline)	Chẩn đoán đa bằng chứng có tối ưu hóa quyết định bảo trì hơn baseline không?	Weighted evidence scoring + Diagnosis + Policy	5 causes, 4 actions	Kết quả thực nghiệm B0–B5, D1–D3 trên 2–3 tasks; Sẵn sàng bài báo Q3 .
Cấp độ Q2 (Nâng cao)	Khung bảo trì có đạt tính vững chắc, tối ưu chi phí và khái quát hóa không?	Calibrated diagnosis + Uncertainty + Pareto cost/risk	Đa miền, trễ nhãn, nhiều	Phân tích Pareto, độ nhạy, khái quát hóa đa bài toán; Ứng viên Q2 mạnh .
Cấp độ Q1 (Đột phá)	Quyết định bảo trì có thể tự thích ứng online hoặc suy luận nhân quả không?	Causal diagnosis hoặc Online adaptive policy	Rộng	Mô hình đột phá mới + kiểm chứng đa miền khắt khe; Tiến tới Q1 .

7.2 Các cổng kiểm soát độ trưởng thành nghiên cứu (Research Maturity Gates)

Để kiểm soát rủi ro và xác định thời điểm hoàn thành sản phẩm nghiên cứu, hệ thống thiết lập 7 cổng kiểm định (Gates):

- **Gate G0 (Design Freeze):** Đóng băng định nghĩa bài toán, RQs, Hypotheses, Taxonomy 5 causes và Action Space.
- **Gate G1 (Benchmark Execution):** Scenario Injector sinh thành công các kịch bản có nhãn chuẩn kép (Cause & Best Action).
- **Gate G2 (Diagnosis Superiority):** Khối chẩn đoán đa bằng chứng vượt trội rõ rệt so với detector đơn lẻ ($D3 > D1$).
- **Gate G3 (Q3 Paper-Ready):** Chính sách thích ứng cắt giảm CT thừa mà không làm suy giảm năng lực phục hồi → **Đóng scope và nộp bài báo Q3**.
- **Gate G4 (Cross-Domain Validation):** Kết quả tái lập ổn định trên 2–3 họ bài toán (Classification, Regression, Forecasting) → **Ứng viên Q2**.
- **Gate G5 (Q2 Strong):** Đạt độ vững chắc cao trước nhãn trễ, bằng chứng nhiều và phân tích tối ưu Pareto Cost-Risk.
- **Gate G6 (Q1 Stretch):** Đạt mô hình chẩn đoán nhân quả (Causal) hoặc chính sách thích ứng online độc lập.

7.3 Kế hoạch triển khai 30 tuần chi tiết

Table 16: Bảng tổng hợp tiến độ nghiên cứu và phát triển 30 tuần.

Giai đoạn	Thời lượng	Mục tiêu trọng tâm	Sản phẩm bàn giao cốt lõi	Ưu tiên	Tiêu chí hoàn thành (Exit Criteria)
Phase 0	Tuần 1–2	Đóng băng thiết kế nghiên cứu (Design Freeze)	Tài liệu định nghĩa bài toán, RQs, Hypotheses, Taxonomy C0–C4, Severity S_0 – S_4 , Action Space và ma trận Ground-truth mapping.	P0	Bảng mapping hoàn chỉnh: Scenario → Cause → Severity → Evidence → Best Action (Gate G0).
Phase 1	Tuần 3–6	Bộ Benchmark & Lát cắt dọc (Vertical Slice)	Bộ dataset tabular, Scenario Injector (sinh nhân cause và best action), vertical slice trên kịch bản S_2 : Detect → Evidence → Policy → CT → Gate.	P0	Luồng dữ liệu khép kín thông suốt giữa các service trên môi trường thử nghiệm (Gate G1).
Phase 2	Tuần 7–10	Hạ tầng Bằng chứng & Nhân trữ	Event contract prediction_id, Feedback API + Store, watermark windowing, thực thể EvidenceWindow, Data Quality checks.	P0	Thực hiện thành công phép join prediction–feedback trên dữ liệu mẫu; truy vết trọn vẹn lineage.
Phase 3	Tuần 11–15	Khối Chẩn đoán Đa tín hiệu (Research Core)	Module chẩn đoán phân loại 5 nhóm nguyên nhân cốt lõi (Cause Probabilities), định lượng Severity S_0 – S_4 , Confidence score, thực thể Diagnosis.	P0	Độ chính xác chẩn đoán vượt trội so với detector đơn lẻ ($D3 > D1$, Gate G2).
Phase 4	Tuần 16–18	Bộ Lựa chọn Chiến lược & Quản trị rủi ro	Module Strategy Selector độc lập: ánh xạ Evidence + Diagnosis → Action Space (No-op, Incremental CT, Full CT, HITL), Approval Inbox.	P0	Hệ thống ngăn chặn hoàn toàn việc tự ý kích hoạt CT khi gặp sự cố dữ liệu hoặc trôi dạt lạnh tính.

Giai đoạn	Thời lượng	Mục tiêu trọng tâm	Sản phẩm bàn giao cốt lõi	Ưu tiên	Tiêu chí hoàn thành (Exit Criteria)
Phase 5	Tuần 19–22	Vòng đời CT Thích ứng & Cổng Thăm định	Kích hoạt Argo Workflow huấn luyện candidate, thực thể EvaluationGate kiểm định đối kháng, chạy toàn diện 6 baseline B_0-B_5 .	P0	Candidate vượt qua cổng kiểm định trước khi đăng ký thăng cấp vào Model Registry (Gate G3 - Q3 Ready).
Phase 6	Tuần 23–24	An toàn Triển khai & Thu hồi (Safe Rollout)	Điều phối Shadow Mode tại gateway, lưu log <code>paas_shadow_logs</code> , cấu hình Canary routing và cơ chế tự động Rollback.	P1/P2	Xác nhận tính an toàn vận hành; không làm ảnh hưởng đến tiến độ đo đạc thực nghiệm cốt lõi.
Phase 7	Tuần 25–30	Thực nghiệm Tổng thể, Ablation & Bài báo	Chạy full benchmark, kiểm định thống kê, Ablation Study A_0-A_4 , phân tích độ nhạy, hoàn thiện bài báo khoa học chuẩn mực.	P0	Đóng gói bài báo hoàn chỉnh sẵn sàng nộp các hội nghị/tạp chí uy tín (Gate G3/G4).

7.4 Nguyên tắc phân bổ Ưu tiên và Kiểm soát Phạm vi (Scope Priority & Rules)

Để bảo đảm tiến độ và chất lượng khoa học, các hạng mục phát triển được phân tầng ưu tiên nghiêm ngặt:

- **P0 (Must Have – Tuyệt đối không cắt giảm):** Scenario Injector, Nhân chuẩn kép (Dual Ground Truth), Biểu diễn đa bằng chứng, Baselines D1/D2/D3, Khối chẩn đoán, Định lượng Severity/Confidence, Bộ lựa chọn chiến lược, Baselines B0–B5 và Đánh giá thực nghiệm.
- **P1 (Should Have – Cần thiết cho tính toàn diện):** Xử lý nhãn trễ, Vòng lặp chuyên gia (HITL), Cổng thăm định Evaluation Gate, Ablation bóc tách bằng chứng, Kiểm định thống kê, Đánh giá trên nhiều bộ dữ liệu.
- **P2 (Nice to Have / Cut First – Cắt giảm đầu tiên nếu thiếu thời gian):** Shadow Mode, Canary Rollout, Tự động thu hồi Rollback, Tối ưu siêu tham số HPO, Chẩn đoán lỗi mã nguồn/hạ tầng, LLM-based diagnosis.

Quy tắc điều hành: Khi gặp áp lực về thời gian hoặc tài nguyên, luôn cắt giảm các hạng mục **P2** trước; tuyệt đối không cắt giảm các khối Chẩn đoán, Chiến lược và Đo đạc thực nghiệm cốt lõi.

8 Thiết kế thực nghiệm và Đánh giá Benchmark Phân tầng

Để khẳng định tính đóng góp khoa học, bộ benchmark thực nghiệm được thiết kế theo nguyên tắc **gắn nhãn chuẩn kép (Dual Ground Truth)**: mỗi kịch bản có cả nguyên nhân suy giảm thực tế (`ground_truth_cause`) và hành động tối ưu kỳ vọng (`ground_truth_best_action`).

8.1 Không gian kịch bản thực nghiệm và Nhãn chuẩn (Benchmark Scenarios)

Table 17: Danh mục các kịch bản thực nghiệm và bảng ánh xạ Ground Truth chuẩn hóa.

Mã	Phân tầng	Bản chất kịch bản (Scenario Injection)	Hành động tối ưu (Best Action)
S0	Cốt lõi (Q3)	Môi trường ổn định, không có suy giảm (Stable)	NO_OP (Không can thiệp)
S1	Cốt lõi (Q3)	Trôi dạt lành tính: $P(X)$ đổi nhưng $P(Y X)$ ổn định	NO_OP / OBSERVE (Log bằng chứng)
S2	Cốt lõi (Q3)	Trôi dạt có hại: $P(X)$ đổi kéo theo F1 giảm, đủ nhãn	INCREMENTAL_CT (Cập nhật gia tăng)
S3	Cốt lõi (Q3)	Sự cố chất lượng dữ liệu: lỗi schema, range, missing	DATA_ENGINEERING (Định chỉ CT)
S4	Cốt lõi (Q3)	Dịch chuyển khái niệm/nhãn: $P(Y X)$ đổi đột ngột	HITL (Chuyên gia phân tích lát cắt)
S5	Cốt lõi (Q3)	Lão hóa dữ liệu huấn luyện (Data Staleness: C4)	FULL_CT (Cập nhật snapshot mới)
S9	Nâng cao (Q2)	Tín hiệu hỗn hợp (Mixed): vừa trôi dạt vừa trễ nhãn	HITL (Thẩm định đa nguồn)
S10	Nâng cao (Q2)	Cảnh báo trôi dạt giả (False Drift Signal)	NO_OP (Nhận diện lành tính, cấm CT)
S11	Nâng cao (Q2)	Nhãn trễ dài hạn / Độ phủ thấp ($r_{\text{labels}} < r_{\text{min}}$)	NO_OP / PROXY_HOLD (Cấm Auto CT)
S6	Mở rộng (Q1)	Suy giảm cấu hình siêu tham số (HPO degradation)	HPO + CT (Tìm kiếm cấu hình)
S7	Mở rộng (Q1)	Lỗi mã nguồn xử lý đặc trưng (Feature code bug)	Sửa đổi qua luồng CI/CD kỹ thuật
S8	Mở rộng (Q1)	Sự cố hạ tầng phục vụ (OOM, nghẽn mạng)	Thu hồi tự động hoặc mở rộng tài nguyên

Cấu trúc metadata chuẩn được Scenario Injector sinh ra hỗ trợ cả kịch bản đơn nguyên nhân lẫn đa nguyên nhân:

```
{
  "scenario_id": "S09_MIXED",
  "ground_truth": {
    "primary_cause": "DATA_DRIFT",
    "secondary_causes": ["DATA_QUALITY"],
    "severity": "S3_HIGH",
    "severity_factors": { "perf_impact": 0.11, "scope": 0.70, "risk": "high" },
    "harmful": true,
    "best_action": "HITL",
    "auto_action_allowed": false
  }
}
```

8.2 Các phương pháp đối chứng (Baselines)

8.2.1 Hệ thống Baselines vận hành toàn trình (End-to-End Maintenance Baselines)

- **B0 – Static / No Retraining:** Mô hình giữ nguyên không tái huấn luyện trong suốt vòng đời; đo lường mức độ suy thoái tự nhiên.
- **B1 – Periodic Retraining:** Tái huấn luyện cố định theo lịch trình định kỳ (hàng tuần/hàng tháng).
- **B2 – Single-Signal Drift-Triggered CT:** Tự động tái huấn luyện ngay khi có bất kỳ cảnh báo data drift đơn lẻ nào.

- **B3 – Performance-Triggered CT:** Chỉ kích hoạt tái huấn luyện khi hiệu năng kiểm chứng thực tế bị suy giảm.
- **B4 – Always Retrain:** Huấn luyện lại liên tục sau mỗi lô dữ liệu mới (đường cơ sở trần về chi phí tài nguyên).
- **B5 – Proposed Degradation-Aware Adaptive CT:** Chuỗi xử lý hoàn chỉnh Detection → Diagnosis → Severity → Strategy Selector → Action Space → Evaluation Gate.

8.2.2 Baselines ở cấp độ chẩn đoán (Diagnosis-Level Baselines)

- **D1 – Single-Signal Detector (Baseline):** Suy luận nguyên nhân chỉ dựa trên một chỉ số trôi dạt duy nhất (ví dụ: khoảng cách Wasserstein hoặc PSI).
- **D2 – Rule-Based Multi-Signal Diagnosis (Heuristic Baseline):** Phân loại dựa trên tập luật điều kiện kết hợp ngưỡng cứng đơn giản.
- **D3 – Proposed Multi-Evidence Weighted Diagnosis (Proposed Method):** Phân loại kết hợp trọng số bằng chứng đa nguồn, khoảng tin cậy thống kê và hiệu chuẩn xác suất.

8.3 Thiết kế Thử nghiệm Bóc tách (Ablation Study)

8.3.1 Bóc tách theo chuỗi thành phần kiến trúc (Core Chain Ablation)

Nhằm chứng minh tính đóng góp của từng khâu trong chuỗi nghiên cứu:

- A_0 : Single-Signal Trigger Baseline (chỉ kích hoạt CT theo một chỉ số drift đơn lẻ).
- A_1 : Thêm biểu diễn bằng chứng đa nguồn (Multi-Signal Evidence Representation).
- A_2 : Thêm khối chẩn đoán nguyên nhân xác suất ($P(\text{Cause} | E)$).
- A_3 : Thêm mô hình định lượng Mức độ nghiêm trọng (S_0-S_4) và Độ tin cậy (Confidence).
- A_4 : Thêm bộ lựa chọn chiến lược thích ứng nhận thức rủi ro (Risk-Aware Strategy Selector).

8.3.2 Bóc tách theo nhóm bằng chứng (Evidence Group Ablation)

Để đánh giá độ nhạy của từng nhóm tín hiệu đối với độ chính xác chẩn đoán:

- A_{Full} : Sử dụng đầy đủ tất cả các nhóm bằng chứng đa nguồn.
- A_{Drift} : Loại bỏ nhóm bằng chứng trôi dạt dữ liệu ($P(X)$).
- A_{Quality} : Loại bỏ nhóm bằng chứng kiểm định chất lượng dữ liệu.
- $A_{\text{Prediction}}$: Loại bỏ nhóm bằng chứng phân phối đầu ra và điểm tự tin ($P(\hat{Y})$, Confidence).
- $A_{\text{Performance}}$: Loại bỏ nhóm bằng chứng hiệu năng thực tế ($P(Y|X)$, F1, Error distribution).
- A_{Lineage} : Loại bỏ nhóm bằng chứng lịch sử huấn luyện, tuổi dữ liệu và lineage.

8.4 Hệ thống chỉ số đánh giá đa chiều (Evaluation Metrics)

Khung đánh giá bao quát 6 chiều cạnh đo lường:

Table 18: Khung chỉ số đánh giá thực nghiệm 6 chiều.

Chiều cạnh đánh giá	Tập chỉ số đo lường chi tiết
A. Chất lượng phát hiện	Precision, Recall, F1 của cảnh báo; False Positive Rate (FPR); Độ trễ phát hiện (Detection Delay).
B. Chất lượng chẩn đoán	Độ chính xác chẩn đoán nguyên nhân (Diagnosis Accuracy); Macro-F1 phân loại các nhóm nguyên nhân; Confusion Matrix; Sai số hiệu chuẩn xác suất (ECE, Brier Score).
C. Lựa chọn chiến lược	Độ chính xác hành động (Strategy Accuracy); Macro-F1 của các lớp hành động; Tỷ lệ hành động mất an toàn (Unsafe Action Rate); Tỷ lệ tái huấn luyện không cần thiết (Unnecessary Retraining Rate - URR); Tỷ lệ bỏ sót suy giảm (Missed Degradation Rate - MDR).

Chiều cạnh đánh giá	Tập chỉ số đo lường chi tiết
D. Năng lực phục hồi	Mức độ phục hồi hiệu năng ($\Delta\text{Recovery}$); Thời gian phục hồi (Time-to-Recovery); Mức cải thiện Candidate-vs-Champion.
E. Chi phí và Nỗ lực	Số lần chạy huấn luyện; Tổng số giờ tính toán (GPU/CPU-hours); Tần suất tái huấn luyện; Số lượng yêu cầu duyệt thủ công (Human Intervention Count).
F. An toàn triển khai	Tỷ lệ thăng cấp thất bại tại Evaluation Gate; Tỷ lệ thu hồi tự động (Rollback Rate); Mức độ suy thoái hiệu năng sau triển khai.

8.5 Ma trận Thực nghiệm Phân tầng (Q3 $\rightarrow$ Q2 $\rightarrow$ Q1 Matrix)

- **Cấp độ Q3 (Baseline Vững chắc – Paper-Ready):** 2–3 bộ dữ liệu tabular chuẩn; 5 nhóm nguyên nhân cốt lõi (C0–C4); 4 hành động cốt lõi; so sánh B0–B5 và D1–D3; Ablation từng nhóm bằng chứng; chứng minh URR $\downarrow$, Chi phí $\downarrow$, Phục hồi duy trì.
- **Cấp độ Q2 (Mở rộng Nâng cao):** Mở rộng sang nhiều họ bài toán (Classification, Regression, Time-series); suy giảm hỗn hợp (mixed causes), trôi dạt dần (gradual drift); cửa sổ nhãn trễ kéo dài; phân tích tối ưu đa mục tiêu Pareto Frontier:

$$U(a \mid E) = \text{Benefit}(a) - \text{Cost}(a) - \text{Risk}(a) - \text{HumanEffort}(a)$$

- **Cấp độ Q1 Stretch (Hướng nghiên cứu Đột phá):** Khung chẩn đoán suy luận nhân quả (Causal Degradation Diagnosis / Counterfactuals) hoặc chính sách học thích ứng online (Online Adaptive Policy / Contextual Bandits) có khả năng khái quát hóa đa lĩnh vực.

9 Quản trị rủi ro và Ranh giới an toàn hệ thống

- **Thách thức về nhãn trễ (Delayed Labels):** Hệ thống áp dụng nguyên tắc phân tách ranh giới giữa giám sát tín hiệu đại diện (Proxy Monitoring) và tính toán hiệu năng đã xác thực (Confirmed Performance); chỉ kích hoạt CT khi độ phủ nhãn r_{labels} đạt ý nghĩa thống kê (chi tiết tại Mục 5.7).
- **Tính mơ hồ trong quan hệ nhân quả (Causal Ambiguity):** Khi xảy ra đồng thời nhiều dạng biến động, khối chẩn đoán xếp hạng các nguyên nhân theo xác suất và tự động rơi về chế độ an toàn HUMAN_REVIEW, tránh việc suy diễn nguyên nhân tuyệt đối khi thiếu chứng cứ.
- **Ngăn ngừa bão tái huấn luyện (Training Storm):** Thiết lập thời gian giãn cách tối thiểu (Cooldown Period) giữa hai lần CT liên tiếp của cùng một mô hình và đặt ngưỡng trần ngân sách tính toán (Budget Cap) theo tuần/tháng.
- **Bảo mật và cô lập đa tenant (Multi-Tenancy Isolation):** Mọi bản ghi sự kiện, dữ liệu phản hồi và truy vấn bằng chứng đều được gắn khóa phân vùng cứng theo `tenant_id`, tuân thủ chính sách lưu giữ và xóa dữ liệu định kỳ.
- **Kiểm soát sai số tổng quát hóa (External Validity):** Các kịch bản thử nghiệm được tạo với nhiều mức cường độ, kết hợp dữ liệu nhiều và độ trễ nhãn ngẫu nhiên trên nhiều hạt giống (seeds) để bảo đảm kết luận thực nghiệm mang tính khách quan.

10 Tổng quan các công trình liên quan và Phân tích khoảng trống

10.1 Khung kiến trúc MLOps và Mô hình trưởng thành

Nghiên cứu của Amou Najafabadi *et al.* [1] là công trình systematic mapping toàn diện nhất hiện nay, phân tích 93 bài báo khoa học để thiết lập khung kiến trúc MLOps chuẩn mực gồm 39 thành phần, 56 quy trình và 8 biến thể kiến trúc. Kreuzberger *et al.* [2] tổng hợp các nguyên lý vận hành, định nghĩa và phân tầng hạ tầng MLOps trong môi trường doanh nghiệp. Mô hình trưởng thành của Google Cloud [4] định nghĩa 3 cấp độ (ML0–ML2), trong đó Continuous Training nằm ở mức trưởng thành cao nhất ML2. Mô hình của Microsoft [5] và nghiên cứu của Granlund *et al.* [14] nhấn mạnh thách thức trong quản trị vòng đời và phân định trách nhiệm đa tổ chức. Tuy nhiên, các khung kiến trúc này dừng lại ở việc mô tả cấu trúc tĩnh hoặc quy định các trigger cơ học, chưa cung cấp giải pháp cụ thể về chẩn đoán nguyên nhân suy giảm và cơ chế ra quyết định thích ứng.

10.2 Giám sát mô hình và Phát hiện trôi dạt

Về mặt thuật toán học thuật, các cơ chế phát hiện trôi dạt kinh điển trên luồng dữ liệu (data streams) gồm ADWIN [9], DDM [10] và tổng quan toàn diện về concept drift của Lu *et al.* [11]. Ở khía cạnh công cụ công nghiệp, Evidently AI [7] cung cấp khả năng tính toán data drift và kiểm tra chất lượng dữ liệu cơ bản; NannyML [8] tập trung vào phương pháp ước lượng hiệu năng (performance estimation) khi chưa có nhãn. Tuy vậy, các công cụ này hoạt động như các module đo lường độc lập, thiếu một vòng lặp khép kín có thể liên kết trực tiếp bằng chứng giám sát với các chính sách can thiệp an toàn và xử lý nhân trữ thông qua mã định danh dự đoán (prediction_id).

10.3 Hệ thống Continuous Training và Tự thích ứng

Luo *et al.* [12] đề xuất pipeline thử nghiệm thích ứng tự động (CTCD-e) dựa trên các công cụ nguồn mở nhằm tự động hóa quy trình huấn luyện và triển khai khi phát hiện drift. Semola *et al.* [13] giới thiệu Continual Learning as a Service (CLaaS) hỗ trợ cập nhật mô hình gia tăng trên điện toán đám mây. Đa số các hệ thống CT hiện nay đều thiết kế theo cơ chế phản xạ: *khi có cảnh báo drift thì tự động kích hoạt huấn luyện lại*. Cách tiếp cận này bộc lộ hạn chế lớn vì chưa phân biệt được trôi dạt lành tính (Benign Drift) với trôi dạt có hại, dẫn đến lãng phí tài nguyên tính toán hoặc tái huấn luyện sai lầm trên dữ liệu rác.

10.4 Quản trị rủi ro, Tính vững chắc và Vòng lặp chuyên gia (HITL)

Bayram & Ahmed [6] khảo sát toàn diện về tính vững chắc (robustness) và quản trị rủi ro trong MLOps, khẳng định việc tự động hóa hoàn toàn mà thiếu kiểm soát an toàn có thể gây thiệt hại nghiêm trọng cho doanh nghiệp. Các nghiên cứu gần đây bắt đầu nhấn mạnh vai trò của Human-in-the-Loop (HITL) trong việc kiểm chứng dữ liệu bất thường và giải quyết các trường hợp suy giảm hiệu năng không rõ nguyên nhân.

10.5 Bảng đánh giá khoảng trống nghiên cứu (Literature Gap Matrix)

Bảng 19 đối chiếu toàn diện hiện trạng y văn và nền tảng hiện hữu với mục tiêu thiết kế của đề tài nghiên cứu theo 7 tiêu chí chức năng cốt lõi:

Table 19: Bảng đối chiếu và đánh giá khoảng trống nghiên cứu.

Công trình / Nền tảng	C1	C2	C3	C4	C5	C6	C7	Khoảng trống chưa giải quyết (Identified Research Gap)
Amou Najafabadi <i>et al.</i> [1]	~	~	×	×	×	×	×	Khung tham chiếu tổng hợp mang tính mô tả; chưa hiện thực hóa thuật toán chẩn đoán hay chính sách CT thích ứng.
Kreuzberger <i>et al.</i> [2]	✓	~	×	×	×	~	×	Định nghĩa CT ở cấp độ kiến trúc tổng quan; kích hoạt CT dạng phản xạ cơ học, thiếu chẩn đoán nguyên nhân và phân tầng Severity.
Luo <i>et al.</i> (CTCD-e) [12]	✓	~	×	×	×	~	~	Tái huấn luyện tự động theo lịch/drift đơn lẻ; thiếu cơ chế phân loại trôi dạt lành tính vs. có hại và thiếu vòng lặp HITL.
Semola <i>et al.</i> (CLaaS) [13]	~	~	×	×	×	~	×	Tập trung thuật toán học liên tục (continual learning); giả định nhân luôn sẵn sàng, thiếu chẩn đoán sự cố dữ liệu.
Evidently AI / NannyML [7, 8]	✓	✓	×	×	×	×	×	Công cụ đo lường và ước lượng trôi dạt độc lập; không có vòng lặp ra quyết định hành động hay điều phối vòng đời CT.

Công trình / Nền tảng	C1	C2	C3	C4	C5	C6	C7	Khoảng trống chưa giải quyết (Identified Research Gap)
Bayram & Ahmed [6]	~	~	×	~	~	×	~	Khảo sát lý thuyết về tính vững chắc và rủi ro; chưa đề xuất một framework vận hành và bộ benchmark định lượng cụ thể.
ADWIN / DDM / Lu [9, 10, 11]	✓	×	×	×	×	×	×	Thuật toán phát hiện biến động trên luồng dữ liệu thô; hoàn toàn nằm ngoài bối cảnh kiến trúc MLOps và pipeline serving/CT.
Nền tảng MLOps hiện hữu	~	~	×	×	×	~	~	Đã có pipeline serving, tracking, model registry và kích hoạt huấn luyện cơ bản; thiếu chẩn đoán đa bằng chứng và chính sách thích ứng.
Mục tiêu thiết kế Đề xuất	✓	✓	✓	✓	✓	✓	✓	Khép kín chuỗi xử lý khoa học: Giám sát đa nguồn → Chẩn đoán đa bằng chứng → Phân tầng Severity → Lựa chọn chiến lược thích ứng → Cổng thẩm định & Triển khai an toàn.

Quy ước ký hiệu: ✓: Hỗ trợ đầy đủ / Mục tiêu thiết kế; ~: Hỗ trợ một phần / Mức khái niệm; ×: Chưa hỗ trợ / Khoảng trống nghiên cứu.

Ghi chú các tiêu chí đánh giá (C1–C7):

- **C1 (Multi-Signal Drift Detection):** Phát hiện đa tín hiệu (Data drift $P(X)$, Prediction drift $P(\hat{Y})$, Data quality).
- **C2 (Performance Monitoring):** Giám sát hiệu năng thực tế ($P(Y|X)$, F1, Precision, Recall).
- **C3 (Delayed-Label Handling):** Xử lý nhãn trễ dựa trên `prediction_id` và cửa sổ trượt watermark.
- **C4 (Root-Cause Diagnosis):** Phân loại nguyên nhân suy giảm cốt lõi và định lượng mức độ nghiêm trọng (S_0 – S_4).
- **C5 (Adaptive Action Space):** Không gian hành động đa nhánh (No-op, Incremental CT, Full CT, HITL).
- **C6 (Safe Evaluation Gate):** Cổng thẩm định đối kháng Champion–Candidate đa tiêu chí trước khi triển khai.
- **C7 (Traffic Experiment & Rollback):** Hỗ trợ Shadow Mode, Canary rollout và cơ chế thu hồi tự động khi vi phạm rào chắn.

10.6 Định vị Công bố Khoa học (Publication Positioning)


Kết quả nghiên cứu của đề tài hướng tới đóng gói bài báo khoa học gửi đến các diễn đàn công bố quốc tế uy tín theo các tầng đóng góp:

- **Đóng góp Cốt lõi (Core Contribution):** Các tạp chí và hội nghị uy tín chuyên sâu về hệ thống và phần mềm: Journal of Systems and Software (JSS), Automated Software Engineering (ASE), Empirical Software Engineering (EMSE), ICSME.
- **Mở rộng Chuyên sâu (Advanced Extension):** Các hội nghị và tạp chí chuyên ngành hàng đầu về thực nghiệm và tiến hóa phần mềm: EMSE, JSS, MSR (Mining Software Repositories).
- **Đột phá Dài hạn (Stretch / Future Direction):** Các diễn đàn hàng đầu thế giới về Công nghệ Phần mềm & AI: IEEE Transactions on Software Engineering (TSE), ACM Transactions on Software Engineering and Methodology (TOSEM), ICSE, ESEC/FSE.

11 Kết luận và Đóng góp khoa học

Quá trình đối chiếu 39 thành phần kiến trúc và 56 bước quy trình khẳng định repository MLOps PaaS đã sở hữu nền tảng vững chắc về quản trị vòng đời mô hình bất biến, hạ tầng huấn luyện đa dạng và kênh thu thập sự kiện suy luận. Đóng góp khoa học cốt lõi của đề tài không phải là việc xây dựng thêm một nền tảng MLOps platform hay gắn thêm trigger tái huấn luyện cơ học, mà là đề xuất và kiểm chứng **Khung bảo trì mô hình thích ứng nhận thức suy giảm (Degradation-Aware Adaptive Model Maintenance Framework)** kết hợp bằng chứng đa nguồn, chẩn đoán nguyên nhân và lựa chọn chiến lược nhận thức rủi ro. Trong cấu trúc này, repository MLOps PaaS đóng vai trò là **nền tảng thực nghiệm nguồn mở (Experimental Platform)** phục vụ đánh giá và tái lập kết quả.

11.1 Bậc thang đóng góp nghiên cứu lũy tiến (Research Contribution Ladder)



Mỗi cấp độ kế thừa trọn vẹn kết quả của cấp độ trước, cho phép đề tài nghiệm thu thành công ở bất kỳ công kiểm định nào mà không bị gián đoạn hay phải tái thiết kế hạ tầng.

11.2 Sáu đóng góp khoa học chính (Key Deliverables)

- Biểu diễn bằng chứng suy giảm đa nguồn (Multi-Evidence Degradation Representation):** Mô hình hóa thống nhất các tín hiệu không đồng nhất từ dữ liệu ($P(X)$), mô hình ($P(Y|X)$), phân phối đầu ra ($P(\hat{Y})$) và bối cảnh huấn luyện lịch sử.
- Cơ chế chẩn đoán nguyên nhân suy giảm (Degradation Cause Diagnosis Mechanism):** Thuật toán xác suất phân loại 5 nhóm nguyên nhân cốt lõi (C0–C4), định lượng mức độ nghiêm trọng độc lập (S_0 – S_4) và điểm tin cậy có thể giải thích được.
- Chính sách can thiệp thích ứng nhận thức rủi ro (Risk-Aware Adaptive Maintenance Policy):** Bộ lựa chọn chiến lược độc lập điều phối không gian 4 hành động cốt lõi (No-op, Incremental CT, Full CT, HITL) có ràng buộc ngân sách và thời gian giãn cách.
- Ranh giới can thiệp của con người (Human-in-the-Loop Boundary):** Định nghĩa tường minh các trường hợp không chắc chắn hoặc rủi ro cao cần chuyển giao chuyên gia nhằm triệt tiêu tự động hóa mất an toàn.
- Bộ Benchmark có kiểm soát với nhãn chuẩn kép (Controlled Dual Ground-Truth Benchmark):** Bộ dữ liệu thực nghiệm 12 kịch bản (S_0 – S_{11}) gắn sẵn cả nguyên nhân thực tế và hành động tối ưu kỳ vọng.
- Đánh giá thực nghiệm so sánh đa chiều (Empirical Evaluation):** Kiểm chứng định lượng tính vượt trội so với 6 baseline vận hành và 3 baseline chẩn đoán về năng lực phục hồi, chi phí tính toán và mức độ an toàn.

References

- [1] F. Amou Najafabadi, J. Bogner, I. Gerostathopoulos, and P. Lago, “An architectural perspective on MLOps: Structures, processes, tools, and stakeholders,” *Information and Software Technology*, vol. 193, Art. 108029, 2026. doi: [10.1016/j.infsof.2026.108029](https://doi.org/10.1016/j.infsof.2026.108029).
- [2] P. Kreuzberger, N. Kühn, and S. Hirschl, “Machine learning operations (MLOps): Overview, definition, and architecture,” *IEEE Access*, vol. 11, pp. 31866–31879, 2023. doi: [10.1109/ACCESS.2023.3262138](https://doi.org/10.1109/ACCESS.2023.3262138).
- [3] MLOps PaaS repository, source inspection of control plane, model server, consumer, Evidently, training, registry, deployment, GitOps manifests, and architecture documentation, accessed August 29, 2026.
- [4] K. Salama, J. Kazmierczak, and D. Schut, “Practitioners guide to MLOps: A framework for continuous delivery and automation of machine learning,” Google Cloud, 2021.
- [5] Microsoft, “MLOps maturity model,” Microsoft Learn, 2025. <https://learn.microsoft.com/en-us/azure/architecture/ai-ml/guide/mlops-maturity-model>.
- [6] F. Bayram and B. S. Ahmed, “Towards trustworthy machine learning in production: An overview of the robustness in MLOps approach,” *ACM Computing Surveys*, vol. 57, no. 5, pp. 1–35, 2025. doi: [10.1145/3697080](https://doi.org/10.1145/3697080).
- [7] Evidently AI, “Evidently: Open-source ML monitoring,” <https://www.evidentlyai.com/>.
- [8] NannyML, “NannyML: Performance estimation and monitoring,” <https://www.nannyml.com/>.
- [9] A. Bifet and R. Gavaldà, “Learning from time-changing data with adaptive windowing,” in *Proc. SDM*, SIAM, 2007, pp. 443–448.
- [10] J. Gama, P. Medas, G. Castillo, and P. Rodrigues, “Learning with drift detection,” in *SBIA*, Springer, 2004, pp. 286–295.
- [11] J. Lu, A. Liu, F. Dong, F. Gu, J. Gama, and G. Zhang, “Learning under concept drift: A review,” *IEEE Trans. Knowl. Data Eng.*, vol. 31, no. 12, pp. 2346–2363, 2019.
- [12] Y. Luo, M. Raatikainen, and J. K. Nurminen, “Autonomously adaptive machine learning systems: Experimentation-driven open-source pipeline,” in *Proc. IEEE International Conference on Software Architecture Companion (ICSA-C)*, 2023, pp. 21–28.
- [13] R. Semola, V. Lomonaco, and D. Bacciu, “Continual-learning-as-a-service (CLaaS): On-demand efficient adaptation of predictive models,” *arXiv preprint arXiv:2305.14864*, 2023.
- [14] T. Granlund, A. Kopponen, V. Stirbu, L. Myllyaho, and T. Mikkonen, “MLOps challenges in multi-organization setup: Recent advances and empirical evidence,” in *Proc. WAIN*, IEEE/ACM, 2021, pp. 88–95.